



**T.C.
İSTANBUL ÜNİVERSİTESİ-CERRAHPAŞA
LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ**

YÜKSEK LİSANS TEZİ

**Yapay Zeka Tabanlı Türkçe Diksiyon Değerlendirme Sistemi: Fonem Düzeyi Geri
Bildirim ve Pedagojik Güvenlik**

Öğrenci Ad SOYAD

**DANIŞMAN
Unvan Ad SOYAD**

**II. DANIŞMAN
Unvan Ad SOYAD**

Anabilim Dalı Adı

Program Adı

Mayıs, 2026

İçindekiler

1. Giriş.....	7
2. Kavramsal Çerçeve.....	12
2.1. Türkçe Telaffuz Değerlendirmesi.....	12
2.2. Hedef Telaffuz ve G2P.....	13
2.3. Fonem Tanıma ve CTC.....	15
2.4. Akustik Referans ve Atlas.....	16
2.5. Türkçe Fonetik Arka Plan.....	17
2.6. Telaffuz Değerlendirme Literatürü.....	18
2.7. Pedagojik Güvenlik.....	19
2.8. Bu Tezin Konumu.....	19
3. Yöntem.....	21
3.1. Araştırma Tasarımı.....	21
3.2. Veri Kaynakları ve Bölme Protokolü.....	21
3.3. Grafem-Fonem Dönüşümü.....	22
Fonem Atlası ve Akustik Özellikler.....	25
wav2vec Fonem-CTC Modeli.....	27
Çalışma Zamanı Hizalama.....	28
Status Tabanlı Değerlendirme Mimarisi.....	29
Değerlendirme Seti.....	31
Metrikler.....	32
Uygulama ve Veri Erişilebilirliği.....	33
4. Bulgular.....	34
4.1. Grafem-Fonem Dönüşüm Bulguları.....	34
4.2. Fonem Atlası Bulguları.....	35
4.3. wav2vec Fonem Tanıma Bulguları.....	39
4.4. Stüdyo Değerlendirmesi.....	43
4.5. Kategori Kırılımı.....	45
4.6. Güvenlik–Tespit Dengesi.....	46
4.7. Status Dağılımının Yorumu.....	48

4.8. Sonuçların Özeti.....	48
5. Tartışma.....	49
5.1. Bulguların Genel Yorumu.....	49
5.2. Status Tabanlı Tasarımın Anlamı.....	49
5.3. Güvenlik ve Tespit Dengesi.....	50
5.4. Tanıma Başarısı Geri Bildirim Güvenliği Değildir.....	50
5.5. Değerlendirme Setinin Sınırları.....	51
5.6. Literatürle İlişki.....	52
5.7. Pedagojik ve Etik Sınırlar.....	52
5.8. Gelecek Çalışma.....	53
5.9. Tartışmanın Özeti.....	53
6. Sonuç ve Öneriler.....	54
6.1. Öneriler.....	56

Özet

Bu tez, Türkçe konuşma kayıtlarından fonem düzeyinde açıklanabilir ve pedagojik açıdan temkinli geri bildirim üreten yapay zeka tabanlı bir telaffuz değerlendirme sistemi geliştirmektedir. Sistem dört bileşenden oluşur: standart İstanbul Türkçesi için 49 birimli IPA tabanlı hedef etiket envanterini birincil vurgu işaretiyle üreten kural tabanlı bir grafem-fonem (G2P) dönüşüm hattı; aynı dağarcıkla ince ayarlanmış wav2vec 2.0 tabanlı bir fonem tanıma modeli; 463.003 segment ve 544,72 saatlik konuşmadan türetilen, yeterli örnekli fonemlerde üç bileşenli, iki seyrek uzun ünlüde tek bileşenli fallback kullanan Gaussian karışım tabanlı bir akustik referans atlası; ve hedef fonem dizisini serbest çözümleme çıktısıyla hizalayarak hedef satırlarında correct, incorrect veya missing, hedefte bulunmayan gözlemlerde ise extra durumu ve sürekli bir fonetik mesafe skoru üreten, ünlülerde akustik tipiklik (kalite) ile süre kanıtını karara müdahale etmeyen ayrı kanallar olarak sunan bir değerlendirme motoru.

Kural tabanlı G2P hattı, uzman seçili Blind-75 setinde 0,015 fonem hata oranı ve %98,52 segmental sembol doğruluğu sağlamıştır. MMS-1B ve XLS-R-300M fonem tanıma modelleri test kümesinde yaklaşık %4,1 Full IPA fonem hata oranıyla birbirine yakın performans göstermiştir. İki anadili Türkçe konuşmacıdan (anonim K1 ve K2) oluşan 150 kayıtlık kontrollü stüdyo setinde sistem, kasıtlı hata konumlarının %65,62'sini incorrect veya missing olarak yakalamıştır; bunun bedeli, doğal-doğru konuşmada işaretli yanlış-pozitif oranının kontrol grubunda %5,29, doğal sözcük grubunda %5,54 düzeyinde kalması ve işaretlenen konumların yalnızca %53,85'inin tasarlanmış hata konumuna düşmesidir.

Çalışmanın temel tezi, “tanıma başarısının” doğrudan “geri bildirim güvenliği” anlamına gelmediğidir: yüksek doğrulukla çözümleyen bir tanıyıcı bile doğal konuşmadaki masum varyasyonu hedef-dışı üretim gibi gösterip pedagojik olarak yanıltıcı işaretler üretebilir. Tez bu riski bir güvenlik–tespit dengesi (frontier) olarak nicelendirir: mevcut iki konuşmacılı doğrulama setinde yanlış-pozitiflerin ve gerçek sapmaların ne fonetik mesafeyle ne de tanıyıcı güveniyle güvenilir biçimde ayırlamadığı; tanıyıcının güvenilir olmadığı (çoğunlukla ünsüz) kontrastlarda çekimser kalan temkinli bir politikanın işaretli yanlış-pozitif oranını %1’in altına indirebildiği, ancak bunun tespiti yaklaşık %30’a düşürdüğü gösterilmiştir. Bu denge, mevcut sistem ve doğrulama kapsamı içinde doğal konuşmada güvenli geri bildirimin sınırını ortaya koyar. Hat, uçtan uca çalışan bir prototip demo olarak sınanmıştır.

Anahtar Sözcükler: Türkçe telaffuz değerlendirmesi, grafem-fonem dönüşümü, wav2vec 2.0, yanlış telaffuz tespiti, pedagojik güvenlik, güvenlik–tespit dengesi.

Abstract

This thesis develops an artificial-intelligence pronunciation-assessment system that produces explainable, pedagogically cautious phone-level feedback from Turkish speech recordings. The system comprises four components: a rule-based grapheme-to-phoneme (G2P) pipeline that generates a 49-unit IPA-based target-label inventory with primary lexical stress for standard Istanbul Turkish; a wav2vec 2.0 phone recognizer fine-tuned on the same vocabulary; a Gaussian-mixture acoustic reference atlas derived from 463,003 segments and 544.72 hours of speech, using three-component models where coverage is sufficient and single-component fallback models for two sparse long vowels; and an evaluation runtime that aligns the target phone sequence against the free-decoded output to assign correct, incorrect, or missing to target rows, extra to targetless observations, and a continuous phonetic-distance score, surfacing vowel acoustic typicality (quality) and duration as separate, non-gating channels.

On the expert-curated Blind-75 set the rule-based G2P pipeline reaches a phone error rate of 0.015 and 98.52% segmental symbol accuracy. The MMS-1B and XLS-R-300M phone recognizers perform comparably, at about 4.1% Full-IPA phone error rate on the test split. On a controlled 150-recording studio set of two native Turkish speakers (anonymous K1 and K2) the system catches 65.62% of intentional-error positions as incorrect or missing; the cost is a flagged false-positive rate of 5.29% on the control group and 5.54% on the natural-word group, with only 53.85% of flagged positions falling on a designed error.

The central claim is that recognition accuracy does not entail feedback safety: even a high-accuracy recognizer can present innocent natural variation as off-target production and emit pedagogically misleading flags. The thesis quantifies this risk as a safety–detection frontier: on the present two-speaker validation set, false positives and genuine deviations separate by neither phonetic distance nor recognizer confidence, and a cautious policy that abstains on recognizer-unreliable (largely consonantal) contrasts can drive the flagged false-positive rate below 1% but only by lowering detection to roughly 30%. This frontier exposes the feedback-safety limit of the current system and validation scope. The pipeline was exercised end-to-end as a prototype demo.

Keywords: Turkish pronunciation assessment, grapheme-to-phoneme, wav2vec 2.0, mispronunciation detection, pedagogical safety, safety–detection frontier.

Kısaltmalar

API: Application Programming Interface (Uygulama Programlama Arayüzü)

ASR: Automatic Speech Recognition (Otomatik Konuşma Tanıma)

CAPT: Computer-Assisted Pronunciation Training (Bilgisayar Destekli Telaffuz Eğitimi)

CTC: Connectionist Temporal Classification (Bağlantıcı Zamansal Sınıflandırma)

DNN: Deep Neural Network (Derin Sinir Ağı)

F1, F2, F3: Birinci, ikinci ve üçüncü formant frekansı

FP: False Positive (Yanlış Pozitif)

GPU: Graphics Processing Unit (Grafik İşlem Birimi)

G2P: Grapheme-to-Phoneme (Grafem-Fonem Dönüşümü)

GMM: Gaussian Mixture Model (Gauss Karışım Modeli)

GOP: Goodness of Pronunciation (Telaffuz İyilik Puanı)

IPA: International Phonetic Alphabet (Uluslararası Fonetik Alfabe)

ISSAI TSC: ISSAI Turkish Speech Corpus (ISSAI Türkçe konuşma derlemi)

LPC: Linear Predictive Coding (Doğrusal Öngörülü Kodlama)

MDD: Mispronunciation Detection and Diagnosis (Yanlış Telaffuz Tespiti ve Tanısı)

MFA: Montreal Forced Aligner (Montreal Zorlamalı Hizalayıcı)

MFCC: Mel-Frequency Cepstral Coefficients (Mel Frekansı Kepstral Katsayıları)

MMS: Massively Multilingual Speech (çok dilli konuşma modeli ailesi)

OOV: Out-of-Vocabulary (Sözlük Dışı)

PER: Phone Error Rate (Fonem Hata Oranı)

VRAM: Video Random Access Memory (Grafik Belleği)

VOT: Voice Onset Time (Ötümlülük Başlama Zamanı)

XLS-R: Cross-lingual Speech Representations (çok dilli konuşma temsil modeli)

Değerlendirme setinde kullanılan istem grubu kodları:

CTL: Kontrol grubu — doğru üretilen kısa ısınma istemleri

W_NAT: Doğal doğru üretilen sözcük ve cümle grubu

W_ERR: Kasıtlı telaffuz hatası içeren sözcük ve cümle grubu

1. Giriş

Etkili sözlü iletişim, yalnızca doğru sözcükleri seçmeye ya da dilbilgisel olarak kabul edilebilir cümleler kurmaya indirgenemez. Konuşanın sesleri anlaşılır biçimde üretmesi ve sözcük akışını dinleyicinin beklediği biçimde sürdürmesi, iletinin doğru algılanmasında belirleyici rol oynar. Bu nedenle telaffuz ve diksiyon, hem anadili Türkçe olan bireylerin mesleki iletişiminde hem de Türkçeyi öğrenen kullanıcıların anlaşılabilirlik ve özgüven kazanma süreçlerinde önemli bir beceri alanıdır (El Kheir vd. 2023; Amrate ve Tsai 2024). Bilgisayar destekli telaffuz öğretimi (Computer-Assisted Pronunciation Training, CAPT) son yirmi yıl boyunca fonem düzeyi hata tespitinden çok boyutlu puanlamaya doğru evrilmiş; ancak bu tez kapsamında taranan literatürde Türkçe için açık veriyle yeniden üretilebilir, fonem düzeyinde çalışan, yanlış-pozitif güvenliğini ölçen ve uçtan uca prototip olarak sınanmış bütünleşik bir CAPT hattı hâlâ sınırlı görünmektedir.

Türkçe, yazı dili ile sesletim arasındaki görece düzenli ilişki nedeniyle ilk bakışta otomatik telaffuz değerlendirmesi açısından kolay bir dil gibi görünebilir. Buna karşın standart İstanbul Türkçesine yakın, operasyonel bir hedef seçildiğinde grafem-fonem dönüşümünün yalnızca harf karşılıklarını üretmekten ibaret olmadığı görülür. Bu hedef, diyalektal ya da bireysel varyantları “yanlış” sayan normatif bir iddia değil, sistemin hangi referansa göre değerlendirildiğini açık tutan deneysel bir seçimdir. Yumuşak g’nin bağlama bağlı yüzeylenmesi (sözcük-sonu konumunda ünlü uzatma, ön ünlü çevresinde palatal yaklaşan [j], art ünlü çevresinde hiatus), alıntı sözcüklerdeki uzun ünlüler (â, î, û ve h-zayıflamasıyla oluşan ikincil uzunluklar), açık /e/ ile /æ/ ayrımı (sonorant kodalı kapalı hecelerde), /k, g/’nin ön ünlülerle palatalize olması (/c, ɟ/), /n/’nin yer benzeşmesi (/ŋ/, /ɲ/), sözcük-sonu /r/ ötümsüzleşmesi (/r̥/) ve Sezer’in bağlı cretic ritmiyle hesaplanan sözcük vurgusu gibi olgular, otomatik sistemin hem beklenen telaffuzu doğru üretmesini hem de konuşma sinyalindeki sapmaları temkinli yorumlamasını gerektirir (Ofлаzer ve Saraçlar 2018; Çöltekin vd. 2023; Sezer 1981; Kabak ve Vogel 2001; Zimmer ve Orgun 1999).

Bu tezin araştırma problemi, Türkçe konuşma kayıtlarından fonetik doğruluk hakkında açıklanabilir ve kullanıcıya dönük geri bildirim üreten bir yapay zeka sisteminin nasıl tasarlanabileceğidir. Çalışmanın amacı yalnızca konuşmayı metne veya fonem dizisine dönüştüren bir tanıyıcı kurmak değildir. Hedef, beklenen fonem dizisini üreten, kaydı bu hedefle hizalayan ve her fonem için bir durum ile sürekli bir skor üreten; belirsiz durumlarda kesin suçlamaya zorlanmayan, açıklanabilir bir telaffuz değerlendirme sistemi geliştirmektir. Bu hedef, hem mühendislik bakımından (Türkçe ses kaynaklarının kısıtlılığı, güvenli geri bildirim politikasının tasarımı) hem de eğitim bilimi bakımından (yanlış yönlü geri bildirimin öğrenme üzerindeki olumsuz etkisi) sınırları belirlenmiş somut bir problemdir.

Bu problem üç araştırma sorusuyla somutlaştırılmıştır. Birincisi, Türkçeye özgü kural tabanlı bir G2P hattı standart hedef fonem dizisini uzman kontrollü ve dış kaynaklı sözlüklerde hangi doğrulukla üretebilir? İkincisi, çok dilli öz denetimli konuşma modelleri Türkçe fonem tanıma için yeterli ve yeniden üretilebilir bir CTC tabanı sağlayabilir mi; bu yeterlilik, aynı test bölümünde XLS-R-300M ve MMS-1B modellerinin Full IPA PER bandı ve segmental PER davranışıyla nasıl ölçülür? Üçüncüsü, G2P hedefi, serbest wav2vec çözümlemesi ve atlas kanıtı birleştirildiğinde fonem düzeyinde status/score geri bildirimi hangi güvenlik–tespit dengesini üretir?

Mevcut CAPT sistemleri büyük ölçüde İngilizce ve diğer yüksek kaynaklı diller üzerine yoğunlaşmıştır. İngilizce için Goodness of Pronunciation (GOP) tabanlı puanlama (Witt ve Young 2000), DNN tabanlı yanlış telaffuz tespiti (Hu vd. 2015) ve çok görevli telaffuz değerlendirme mimarileri (Gong vd. 2022; Chen vd. 2024) olgunlaşmış bir literatüre sahiptir. L2-ARCTIC (Zhao vd. 2018) ve speechocean762 (Zhang vd. 2021) gibi açık L2 corpus’ları, İngilizce öğrencilerinin hata profillerinin sistematik incelenmesini mümkün kılmıştır. Buna karşın Türkçe için bu tez kapsamında taranan çalışmalar, açık veriyle yeniden üretilebilir ve fonem düzeyinde yanlış-pozitif davranışını ölçen bütünleşik bir telaffuz geri bildirimi hattı sunmamaktadır. Mevcut Türkçe ASR sistemleri (Salor vd. 2002; Sak vd. 2012; Tombaloğlu ve Erdem 2016) sözcük tanıma doğruluğunu optimize eder, ancak fonem düzeyinde pedagojik kullanıma dönük geri bildirim üretmek üzere tasarlanmamıştır. Türkçe fonolojisinin yapısal özellikleri — yumuşak g’nin bağlamsal yüzeylemesi, açık /e/ kontrastı, palatal/velar ayrımı, uzun ünlü kalıpları ve Sezer vurgu kuralları — genel amaçlı CAPT sistemlerinin doğrudan aktarımıyla çözülemeyecek düzeyde dil-özgü karmaşıklık taşır.

Geliştirilen sistem dört ana bileşenden oluşur. İlk bileşen, Türkçenin yazımdan sesletime dönüşümünü kural tabanlı ve istisna duyarlı biçimde modelleyen grafemden foneme (G2P) hattıdır. İkinci bileşen, Türkçe hedef etiket envanteriyle ince ayarlanmış wav2vec 2.0 tabanlı bağlantıcı zamansal sınıflandırma (CTC) modelidir; varsayılan kontrol noktası MMS-1B üzerinde ince ayarlanmış, XLS-R-300M karşılaştırma için yan yana tutulmuştur (Baevski vd. 2020; Babu vd. 2022; Pratap vd. 2024). Üçüncü bileşen, çok konuşmacılı fonem atlasından türetilen akustik referans modelidir; yeterli örnekli 47 fonem için üç bileşenli Gaussian karışım modeli, /u:/ ve /y:/ için ise tek bileşenli fallback ve süre dağılımı saklanır. Dördüncü bileşen ise hedef fonem dizisini tanıyıcının serbest çözümlemesiyle hizalayan ve hedef satırları için correct, incorrect veya missing, hedefte bulunmayan fazladan gözlemler için extra durumu ile sürekli bir fonetik mesafe skoru üreten değerlendirme motorudur; ünlülerde akustik tipiklik

(kalite) ve süre, fonem kimliğini geçersiz kılmayan ayrı kanallar olarak raporlanır. Bu dört bileşen aynı 49 birimli IPA tabanlı hedef etiket envanterini paylaşır; bu paylaşılan envanter, eğitim CTC etiketleriyle çalışma zamanı hedef dizilerinin aynı sembol uzayında kalmasını sağlar.

Bu mimaride amaç, kullanıcının konuşmasını yalnızca “doğru” ya da “yanlış” olarak sınıflandırmak değildir. Sistem, beklenen fonem kimliğinin kayıta desteklenip desteklenmediğini hedef-gözlem hizalamasıyla, üretimin akustik olarak ne kadar tipik olduğunu ise ünlülerde atlas kalite kanıtıyla ayrı ayrı izler. Bu ayırım eğitim amaçlı kullanımda önemlidir; çünkü doğruya yakın bir üretimi yanlış diye işaretlemek, sorunlu bir üretimi kaçırmak kadar pedagojik risk taşır. Bununla birlikte bu tez öğrenme kazanımı, kullanıcı motivasyonu, öğretmen geri bildirimiyle uyum ya da anlaşılabilirlik etkisi ölçmemektedir; “pedagojik güvenlik” burada kullanıcıya dönük kesin hata bildiriminin yanlış-pozitif riskini azaltma ve belirsizliği görünür kılma ilkesi anlamında kullanılır. Bu nedenle hizalama çıktısındaki durumlar birbirinden farklı pedagojik anlam taşır: correct hedef fonemin desteklendiğini, incorrect hedefin başka bir analiz fonemine hizalandığını, missing hedefin gözlem dizisinde karşılık bulamadığını, extra ise hedef satırı olmayan fazladan bir gözlemi belirtir. Durum etiketinin yanında üretilen sürekli fonetik mesafe skoru sapmanın şiddetini derecelendirir; kalite ve süre kanalları ise kullanıcıya, fonem kimliğini geçersiz kılmadan açıklayıcı kanıt sunar. Sistemin temel güvenlik ilkesi, tanıyıcı çıktısını tek başına kesin öğretmen otoritesi gibi sunmamak ve ham tanıma, akustik analiz ile nihai hizalamayı ayrı bloklar hâlinde raporlamaktır.

Çalışmanın veri ve deney temeli, 75 istemlik Türkçe konuşma seti ve iki anadili Türkçe konuşmacıdan (anonim olarak K1 ve K2) oluşan doğrulama oturumlarına dayanır. Her iki konuşmacı da tüm 75 istemi okumuştur; toplam değerlendirme seti 150 kayıttır. İstemler üç gruba ayrılır: CTL doğal kontrol cümleleri, W_NAT doğal hedef telaffuzlu sözcükler ve W_ERR konuşmacıların kasıtlı olarak ürettiği yanlış telaffuz örnekleri. Bu üçlü tasarım, sistemin hem doğal-doğru konuşmada yanlış-alarm üretip üretmediğini hem de hedeflenen fonetik sapmaları yakalayıp yakalamadığını eş zamanlı ölçer. Toplam hedef fonem sayısı CTL için 454, W_NAT için 1.498 ve W_ERR için 372’dir. Doğal-doğru gruplarda durumu correct olmayan (işaretli) hedef fonem sayısı CTL’de 24 (18 incorrect, 6 missing), W_NAT’te 83 (63 incorrect, 20 missing) olarak gerçekleşmiş; W_ERR grubunda ise 64 kasıtlı hata konumunun 42’si işaretlenmiştir. Bu sayılar Bulgular bölümündeki sonuç tablosuyla birebir tutarlıdır. Değerlendirme kontrollü stüdyo okuması yapan iki anadili konuşmacıyla sınırlandırılmıştır; bu

kapsam, regresyon ve sistem davranışı okumak için yeterlidir ancak W_ERR grubu doğal L2 hata dağılımı ya da öğretmen puanlı öğrenci doğrulaması yerine geçmez.

Tezin katkıları beş başlıkta özetlenebilir. Birincisi, Türkçeye özgü 49 birimli IPA tabanlı hedef etiket envanteri ve vurgu işaretiyle çalışan, 15 ardışık fonolojik kural artı istisna sözlüğü içeren kural tabanlı G2P hattıdır; Blind-75 uzman setinde PER = 0,015 ve segmental sembol doğruluğu %98,52 düzeyine ulaşmıştır. İkincisi, aynı 54 birimli CTC dağılımıyla eğitilmiş XLS-R-300M ve MMS-1B fonem tanıma modellerinin karşılaştırılmasıdır; iki model de test kümesinde Full IPA PER bakımından %4,1 bandında benzer performans sergiler. Üçüncüsü, 463.003 segment ve 544,72 saatlik konuşmadan türetilen, yeterli örnekli fonemlerde üç bileşenli GMM, iki seyrek uzun ünlüde tek bileşenli fallback ve fonem-özümler quantile dönüşümüyle çalışma zamanı kalite puanına çevrilen akustik referans modelidir. Dördüncüsü, hedef-gözlem hizalamasından durum (correct, incorrect, missing, extra), fonetik mesafeden sürekli skor ve atlas/süre kanıtını karara müdahale etmeyen ayrı kanallar olarak üreten phonetic-distance-v1 çalışma zamanı sözleşmesi ve bu sözleşmenin iki anadili konuşmacılı sette nicelendirilen güvenlik-tespit dengesidir. Beşincisi, bu hattın demo sunucu ve push-to-talk arayüzle uçtan uca prototip olarak çalıştırılmasıdır.

Sayısal sonuçların önizlemesi olarak: sistem kasıtlı hata konumlarının %65,62'sini (42/64) yakalarken, doğal-doğru gruplarda işaretli yanlış-pozitif oranı CTL için %5,29, W_NAT için %5,54 düzeyinde kalmıştır; işaretlenen konumların %53,85'i (42/78) tasarlanmış hata konumuna düşer (precision-at-error). Bu oranlar, çekimser bant uygulanmayan ve incorrect ile missing durumlarını birlikte işaretli sayan status sözleşmesinin katı güvenlik okumasıdır. Tez, bu güvenlik-tespit dengesini açık bir frontier olarak raporlar (Bölüm 4 ve 5): mevcut iki konuşmacılı set, serbest çözümleme + status politikası ve kullanılan skor/güven sinyalleri altında tanıyıcının güvenilir olmadığı kontrastlarda çekimser kalan bir politika işaretli yanlış-pozitif %1'in altına çekebilir, fakat aynı anda tespiti yaklaşık %30'a düşürür. Konuşmacı sayısı iki olduğundan bu oranların güven aralıkları geniştir ve sayılar nokta tahmininden çok davranışsal eğilim olarak okunmalıdır. Bu davranış, bulgular ve tartışma bölümlerinde “tanıma başarısı $\neq$ geri bildirim güvenliği” tezi çerçevesinde ele alınır (Guo vd. 2017).

Bu kapsam, tezin sınırlarını da belirler. Çalışma klinik konuşma bozukluğu tanısı ya da terapi amaçlı değerlendirme sistemi geliştirmemektedir. Ayrıca gerçek Türkçe öğrencileri üzerinde geniş popülasyon genellemesi yapılmamıştır; öğrenme kazanımı, öğretmen puanıyla uyum ve anlaşılabilirlik etkisi bu tezin deneysel kapsamı dışındadır. Deneyler kontrollü

konusmacılar ve bilinçli yanlış telaffuz senaryolarıyla sınırlandırılmıştır. Çocuk konuşması, işitme engelli konuşması, diyalektal varyantlar ve farklı ana dil profilleri gelecek çalışma kapsamındadır. Aynı şekilde tonlama, ritim ve akıcılık gibi cümle düzeyi prozodik özellikler de bu tezde yalnızca fonem süresi kanalı üzerinden yumuşak biçimde ele alınır; kapsamlı prozodi puanlama bu çalışmanın hedefi değildir.

Tez altı ana metin bölümünden oluşmaktadır. Kavramsal Çerçeve, Türkçe fonolojisinin ilgili olgularını, G2P teorik temellerini, wav2vec/CTC mimarisini ve telaffuz değerlendirme literatürünü sistematik biçimde özetler. Yöntem, G2P hattı, veri kaynakları ve bölme protokolü, wav2vec eğitimi, fonem atlası oluşturma ve değerlendirme motorunun teknik ayrıntılarını sunar. Bulgular, G2P benchmark sonuçları, wav2vec PER karşılaştırmaları, atlas istatistikleri ve iki anadili konuşmacılı sistem değerlendirmesini raporlar. Tartışma, sistemin güvenlik odaklı geri bildirim perspektifinden anlamını, güvenlik–tespit dengesini, sınırlılıklarını ve literatürle ilişkisini değerlendirir. Sonuç ve Öneriler bölümü ise temel çıktıları ve gelecek çalışma yönlerini özetler.

2. Kavramsal Çerçeve

2.1. Türkçe Telaffuz Değerlendirmesi

Türkçenin yazı-ses ilişkisi görece düzenlidir; ancak bu düzenlilik otomatik telaffuz değerlendirmesini tek başına çözmez. Standart İstanbul Türkçesine yakın operasyonel bir hedef seçildiğinde uzun ünlüler, açık /e/, palatal/velar ayrımlar, yumuşak g, ünsüz benzeşmeleri, son ses /r/ davranışı ve sözcük vurgusu gibi alanlar ayrı modellenmelidir (Göksel ve Kerslake 2005; Kornfilt 1997; Zimmer ve Orgun 1999; Demircan 1996; Selen 1979; Underhill 1976; Lewis 2000; Ergenç 1995). Bu hedef, diyalektal veya bireysel varyantları değersizleştiren bir normatif çerçeve değil, deneysel sistemin hangi referans dizisiyle çalıştığını belirleyen açık bir tasarım kararıdır.

Bu olguların bir bölümü yazıdan doğrudan okunabilir, bir bölümü ise istisna sözlüğü, akustik ölçüm veya bağlam bilgisi gerektirir. Bu tezde kullanılan grafemden foneme (G2P) hattı 15 kural modülü ile modellenmiştir: yumuşak g'nin bağlamsal yüzeylenmeleri, koyu/açık l allofonisi, v allofonisi, k/g palatalizasyonu, n yer benzeşmesi, açık /e/ kuralı, aspirasyon, r ötümsüzleşmesi, ünlü uyumu, alıntı uzun ünlüler, y/h zayıflaması, daralma, ünsüz yumuşaması, özel sözcüksel öğeler ve vurgu hesaplaması. Türkçe için bu ayrımı dikkate alan kural tabanlı G2P çalışmaları az sayıdadır; özellikle alıntı sözcüklerdeki uzun ünlü kalıpları ve Sezer'in bağlı cretic kuralıyla işleyen vurgu tahmini, salt harf-ses eşlemesinin ötesine geçen yapısal kararlar gerektirir (Altınok 2016; Sezer 1981; Kabak ve Vogel 2001).

Bu tezde “hata” terimi klinik bir bozukluk anlamında değil, hedeflenen telaffuz dizisiyle kayıta gözlenen üretim arasındaki öğretimsel sapma anlamında kullanılır. Sistem kullanıcının tüm konuşma becerisini puanlamaz; fonem düzeyinde hedef destekleniyor mu ve üretim akustik olarak tipik mi sorularına yanıt verir. Bu yüzden geri bildirim mimarisi sözcük tanımadan farklıdır: yüksek doğrulukla sözcüğü doğru çözen bir otomatik konuşma tanıma (ASR) sistemi, fonem düzeyinde akustik tipikliği veya hedeflenen ayrımı garanti etmez. Türkçeye özgü /e/–/æ/, /i/–/ɪ/, /l/–/ʎ/ ve kısa–uzun ünlü ayrımları, dilbilgisel doğru sözcüğü etkilemese bile pedagojik açıdan ayrı izlenmesi gereken kontrastlardır.

2.1.1. Türkçe Fonolojisinin İlgili Olguları

Aşağıdaki olgular hem G2P hattının üretmesi gereken hedef yapıyı hem de wav2vec/atlas katmanlarının ayırt etmesi beklenen kontrastları belirler. Bu liste tez metnindeki kural numaralarıyla eşleşir.

Yumuşak g (ğ). Yazımda görünen ğ bağımsız bir foneme karşılık gelmez; bağlama göre altı farklı yüzey gerçekleşmesi vardır: sözcük-sonu / kapanışta uzatma (dağ → /da:/), e sonrası [j] (değnek → /dej'nec/), ön ünlü çevresinde palatal yaklaşan [j] (değil → /de'jil/), art ünlü

çevresinde hiatus (oğul → /o.'ul/), özel adlarda ünsüz sonrası /g/ (Olğun → /ol'gun/) ve alıntılarda ğ-ekleme baskısının kaldırılması (Irak'ı → /i'rakw/). Bu altı durum kural tabanlı G2P'de açıkça ayrılmış, ezberlenmiş bir istisna gerektirmemiştir.

Açık /e/ (/æ/). /e/ fonemi, kodası sonorantla (l, m, n, r, j) başlayan kapalı hecelerde ve belirli sözlüksel eklerde (-mez gibi) /æ/'ye açılır: el /æɫ/, ders /dærs/, denk /dæŋk/, gelmez /jæɫ'mæz/. Patlayıcı/sürtünmeli kodada /e/ kalır: ekmek /ek'mec/. Bu kontrast yazıda görünmediğinden öğrenici geri bildiriminde özellikle değerlidir.

/k, g/ palatalizasyonu. Ön ünlülerle (e, i, ö, ü, æ) komşu olduklarında /k/ → /ç/, /g/ → /j/: kedi /'cedi/, gece /je'dʒe/. Alıntılarda circumflex'li ünlüler (â, û) art ünlü olmalarına rağmen palatalizasyonu tetikleyebilir: kâr /ca:ɾ̥/.

Sözcük-sonu /ɾ/ ötümsüzleşmesi. Sözlü Türkçede sözcük-sonu ya da ötümsüz ünsüz öncesi /ɾ/, daraltılmış ve ötümsüzleşmiş bir [ɾ̥] olarak gerçekleşir: bir /biɾ̥/, kart /kaɾ̥/. Bu pedagojik allofon, hedef envanterde açıkça tutulur; değerlendirme motoru standart bir tipik üretimi hata olarak işaretlemekten kaçınır.

Vurgu. Türkçede varsayılan vurgu sözcük-sonudur; ancak alıntılar, yer adları, bileşik sözcükler ve belirli ek sınıfları (ön-vurgulu -me, -le, -ki; vurgu çeken -iyor, -ince, -iver) bu varsayılanı bozar. Yer adlarında Sezer'in cretic ritmi (ağır-hafif-hafif örüntüsünde antepenultimate'i ağırlıklandıran kural) uygulanır (Sezer 1981; Kabak ve Vogel 2001): Ankara /'ankara/, Adana /a'dana/.

Uzun ünlüler. Türkçedeki uzun ünlüler hem alıntılardan (circumflex'li â, î, û) hem fonolojik süreçlerden (coda ğ uzatması, intervokalik h zayıflaması, y zayıflaması) doğar. CTC dağarcığında bu sekiz uzun ünlü (/a:, e:, i:, u:, o:, æ:, u:, y:/) kısa ünlüden ayrı atomik token olarak temsil edilmiştir; bu tercih, CTC collapse adımıyla süre bilgisinin kaybolmasını önlemek için yapılmıştır.

2.2. Hedef Telaffuz ve G2P

Otomatik değerlendirme için önce beklenen fonem dizisinin güvenilir biçimde üretilmesi gerekir. Türkçe için kural tabanlı G2P yaklaşımı, yazı sisteminin düzenliliği nedeniyle güçlü bir başlangıç noktası sunar. Ancak alıntı sözcükler, yer adları, uzun ünlüler ve vurgu istisnaları için salt harf-ses eşlemesi yeterli değildir (Altınok 2016; Sezer 1981; Oflazer ve Saraçlar 2018). İstatistiksel ve nöral G2P modelleri (LSTM, Transformer tabanlı) düşük kaynaklı diller için güçlü genellemeler sağlamış olsa da (Rao vd. 2015; Yolchuyeva vd. 2019), bu yaklaşımlar büyük telaffuz sözlükleri gerektirir ve istisna davranışını sözlük dışı sözcükler için aktarmakta zorlanır. Türkçenin yazımının yüksek tutarlılığı ve fonolojik

olguların düzenli kurallaştırılabilir yapısı, kural tabanlı bir hattın hem doğrulanabilir hem de pedagojik açıdan denetlenebilir bir hedef üretmesini mümkün kılar.

Bu çalışmadaki G2P hattı 49 birimli Uluslararası Fonetik Alfabe (IPA) tabanlı hedef etiket envanteri üretir. Envanter sekiz kısa ünlü (a, e, i, u, o, æ, ʊ, y), sekiz atomik uzun ünlü (a:, e:, i:, u:, o:, æ:, ʊ:, y:), bir ünlü allofonu (æ), 20 temel ünsüz, yedi temel ünsüz allofonu (c, ɟ, ɲ, ŋ, ɬ, β, ʙ) ve beş pedagojik allofon (p^h, t^h, k^h, c^h, ɾ) içerir; ek olarak birincil vurgu işareti (') suprasegmental olarak tutulur. Bu envanter hem CTC dağıtıcısında (toplam 54 token: 4 özel + 49 hedef etiketi + 1 vurgu) atomik etiket olarak hem de çalışma zamanı değerlendirmesinde beklenen fonem sırası olarak kullanılır. Aynı sembol kümesinin paylaşılması, eğitim/etiket uzayı ile değerlendirme hedef uzayı arasında izlenebilir bir bağ kurar; ancak kullanıcıya dönük geri bildirim hâlâ hedef-gözlem hizalaması ve güvenlik politikasıyla sınırlanır.

2.2.1. G2P Teorik Temelleri

Grafemden foneme dönüşüm yaklaşımları üç temel paradigma altında incelenebilir. Kural tabanlı yaklaşımlar, dilin fonolojik kurallarını insan uzmanlığıyla kodlayarak grafem dizisini fonem dizisine dönüştürür. Bu yaklaşımın en büyük avantajı doğrulanabilirlik ve denetlenebilirliktir: her kuralın girdi-çıkışı ilişkisi açıkça izlenebilir, istisnalar sözlük bazlı olarak ele alınabilir ve pedagojik geri bildirimde hangi kuralın hangi aşamada devreye girdiği açıklanabilir (Altinok 2016; Oflazer ve Saraçlar 2018). Kural tabanlı sistemlerin dezavantajı ise dilin tüm istisnalarını kapsamak için geniş bir kural ve istisna sözlüğü setinin manuel olarak hazırlanması gerekliliğidir; bu, özellikle alıntı sözcükler, yer adları ve neolojizmler için ölçeklenme zorluğu yaratır.

İstatistiksel G2P yaklaşımları, eldeki telaffuz sözlüklerinden otomatik olarak grafem-fonem eşleme kurallarını çıkarır. Joint-sequence model (JSM) (Bisani ve Ney 2008) ve Conditional Random Field (CRF) tabanlı modeller, grafem-fonem çiftlerinin ortak olasılık dağılımını öğrenir. Bu yaklaşımlar kural tabanlı sistemlere göre daha az manuel çaba gerektirir, ancak büyük ve kaliteli telaffuz sözlüklerine bağımlıdır. Düşük kaynaklı diller için uygun sözlüklerin bulunmaması, istatistiksel modellerin genelleme gücünü sınırlar.

Nöral G2P yaklaşımları, LSTM (Rao vd. 2015) ve Transformer (Yolchuyeva vd. 2019) mimarileriyle diziden diziye öğrenme gerçekleştirir. Encoder-decoder yapısı, grafem dizisini fonem dizisine eşlerken dikkat (attention) mekanizması uzun mesafe bağımlılıklarını yakalayabilir. Nöral modeller, istisna davranışını sözlük dışı (OOV) sözcüklere aktarmada istatistiksel modellere göre üstün performans gösterir. Ancak nöral G2P'nin “kara kutu” doğası, pedagojik uygulamalarda hangi kuralın hangi çıktıyı ürettiğini açıklamayı zorlaştırır. Türkçe gibi yazım-sesletim ilişkisi düzenli bir dilde, kural tabanlı hattın doğrulanabilirliği ve istisna davranışını denetlenebilir biçimde ekleme imkânı bu çalışma için daha uygun görülmüştür;

nöral G2P ile kapsamlı bir karşılaştırma bu tezin deneysel kapsamına alınmamıştır.

2.3. Fonem Tanıma ve CTC

Öz denetimli konuşma modelleri, düşük ve orta kaynaklı dillerde fonem tanıma için güçlü bir altyapı sağlamıştır. wav2vec 2.0 ve onun çok dilli devamı XLS-R, etiketsiz konuşmadan öğrenilen kuantize edilmiş gizli temsillerle fonem tanıma gibi uygulama görevlerine güçlü aktarım sağlar (Baevski vd. 2020; Babu vd. 2022). MMS (Massively Multilingual Speech), aynı mimari aileyi 1.000’i aşkın dile genişleterek özellikle az kaynaklı diller için daha yüksek dil kapsamı sağlar (Pratap vd. 2024). Bu tezde 24 katmanlı XLS-R-300M (yaklaşık 317 milyon parametre) ile 48 katmanlı MMS-1B (yaklaşık 1 milyar parametre) yan yana ince ayarlanmış; özellik çıkarıcı CNN dondurulmuş, yalnızca transformer yığını ve rastgele başlatılan CTC projeksiyonu güncellenmiştir. İnce ayar süreci toplam 57 GPU-saat sürmüştür. Eğitim verisi olarak başlangıçta ~344 saat ham Türkçe konuşma derlenmiş; otomatik kalite filtreleme ve hizalama doğrulaması sonrasında 275,48 saatlik eğitim seti elde edilmiştir. Bu veri hacmi, mevcut karşılaştırma için kullanılabilir bir öz denetimli aktarım tabanı sağlamıştır. HuBERT gibi alternatif öz denetimli modeller (Hsu vd. 2021) ve büyük ölçekli zayıf gözetimli Whisper hattı (Radford vd. 2023) de aynı çerçevede değerlendirilebilir; bu tezde MMS-1B ve XLS-R-300M karşılaştırması Türkçe için iki güçlü çok dilli başlangıç noktasını yan yana sınamıştır.

Connectionist Temporal Classification, açık çerçeve hizalaması gerektirmeden değişken uzunluklu ses girdisini fonem dizisine bağlamaya olanak verir (Graves vd. 2006). CTC blank tokenı ve tekrar daraltma adımı, modelin tekrar eden çıktı dizilerinden tek bir referans diziye geri dönüşünü mümkün kılar; ancak bu daraltma adımı, fiziksel olarak uzun bir ünlüyü [a, a, a] gibi tekrarlamayla değil, atomik bir /a:/ etiketiyle temsil etmeyi gerektirir. Bu tezdeki dağarcık tasarımı bu kısıt göz önünde bulundurularak yapılmıştır.

2.3.1. CTC ve wav2vec Matematiği

CTC’nin matematiksel temelleri, değişken uzunluklu girdi dizisinden hedef dizisine olasılık hesaplamasına dayanır. T çerçevelik ses girdisi $x=(x_1, \dots, x_T)$ ve U uzunluklu hedef fonem dizisi $y=(y_1, \dots, y_U)$ için, CTC modeli her çerçeve için dağarcık boyutu V üzerinden bir posterior dağılımı $P(k | x_t)$ üretir. CTC blank sembolü (<blank>) ile birlikte, model tüm geçerli hizalamalar üzerinden toplama yapar:

$$P(y | x) = \sum_{\pi \in B^{-1}(y)} \prod_{t=1}^T P(\pi_t | x_t)$$

burada B , blank kaldırma ve tekrar daraltma işlemini temsil eden CTC birleştirme fonksiyonudur. Bu toplama, ileri-geri (forward-backward) algoritmasıyla dinamik programlama yoluyla verimli biçimde hesaplanır. Eğitim sırasında kayıp fonksiyonu, negatif log-olasılık olarak tanımlanır:

$$L_{\text{CTC}} = -\log P(y | x)$$

Bu formülasyon, modelin hangi çerçevenin hangi foneme karşılık geldiğini önceden bilmeksizin, tüm olası hizalamalar üzerinden marjinalizasyon yaparak öğrenmesini sağlar. wav2vec 2.0 mimarisinde, öz denetimli ön-eğitim aşamasında kuantize edilmiş gizli temsiller ve karşılıklı kaybı ile öğrenilen temsiller, CTC görevine aktarılır (Baevski vd. 2020). Bu tezde kullanılan MMS-1B modeli, 1.000’i aşkın dilde ön-eğitim yapılmış geniş bir temsilden Türkçe fonemleri üzerinde ince ayarlanmıştır.

Goodness of Pronunciation (GOP) metriği, beklenen fonemin akustik destek düzeyini ölçmek için log-olasılık farkından yararlanır (Witt ve Young 2000; Neumeyer vd. 2000; Hu vd. 2015). Her fonem penceresi için:

$$GOP(p | x) = \frac{1}{T} \sum_{t \in \text{pencere}(p)} [\log P(p | x_t) - \log P(p^{\hat{}} | x_t)]$$

burada p beklenen fonem, $p^{\hat{}} = \arg \max_{q \in V} P(q | x_t)$ ise aynı çerçevedeki en olası fonemdir. pencere(p), klasik GOP kullanımında beklenen foneme ayrılan zorlamalı ya da hizalama-temelli zaman aralığını belirtir; bu tezde GOP formülü nihai çalışma zamanı kararının kendisi değil, beklenen fonem desteğini açıklayan kavramsal temeldir. GOP skoru negatif değerler alır; sıfıra yakın değerler güçlü desteği, büyük negatif değerler ise zayıf desteği gösterir. Bu metrik tek başına yeterli değildir çünkü (a) tanıyıcının kendinden emin fakat yanlış alternatif üretme olasılığını ayırt edemez, (b) akustik tipiklik hakkında bilgi vermez ve (c) kontrast başına yanlış-pozitif oranını kontrol etmez. Bu tezde GOP literatürü, beklenen fonemin akustik desteğini yorumlamak için kavramsal temel sağlar; kullanıcıya dönük nihai çıktı ise phonetic-distance-v1 ile üretilen status/score hizalamasıdır.

Ancak düşük fonem hata oranı, doğrudan güvenli telaffuz geri bildirimi anlamına gelmez. Bir tanıyıcı belirli bir kaydı doğru çözebilir ama hedeflenen öğretimsel kontrast hakkında yeterli kanıt üretmeyebilir. Tersine, model bir fonem için kendinden emin bir alternatif üretebilir; bu durum kullanıcının gerçekten yanlış ürettiğini ya da modelin hedef kontrastta kararsız olduğunu tek başına göstermez. Mispronunciation Detection and Diagnosis (MDD) literatürü bu ayrımı, eklenmiş tanıma ağırları, çok dağılımlı sinir ağırları, sıralama tabanlı puanlama ve transformer tabanlı uçtan uca tanımlarla incelemiştir (Harrison vd. 2009; Li vd. 2017; Leung vd. 2019; Wu vd. 2021). Bu nedenle fonem tanıma çıktısı değerlendirme motorunda tek karar kaynağı değildir; çalışma zamanı ham wav2vec çıktısını, akustik analiz adaylarını ve nihai status/score hizalamasını ayrı bloklarda raporlar.

2.4. Akustik Referans ve Atlas

Fonem atlası, beklenen fonemlerin Türkçe konuşma verisinde hangi akustik aralıklarda gözlemlendiğini belgeleyen referans katmanıdır. Mozilla Common Voice 24.0 Türkçe alt kümesi, ISSAI Turkish Speech Corpus ve kamu malı sesli kitap kayıtlarından oluşan 544,72 saatlik bütüne dayanarak 463.003 segment ve 22,4 milyon fonem penceresi üzerinde formant, süre,

hizalama aralığı ve hece düzeyinde belirginlik ölçümleri saklanır (Ardila vd. 2020; Institute of Smart Systems and Artificial Intelligence (ISSAI), Nazarbayev University 2022). Bu ölçümler ham tanıma çıktısından farklı bilgi taşır: ünlü kontrastlarında F1/F2 ölçümleri, uzun ünlülerde süre ilişkisi, lateral allofonisinde F2 farkı tanısal ipucu sağlar. Atlas, yeterli örnekli 47 fonemde üç bileşenli, iki seyrek uzun ünlüde tek bileşenli fallback kullanan Gaussian karışım modeli (GMM) parametre kümesine indirgenir; çalışma zamanında ölçülen akustik vektör bu GMM'in log-yoğunluğuyla karşılaştırılır ve mevcut kullanıcıya dönük sürümde özellikle ünlülerde quality kanıtı olarak raporlanır. Praat tabanlı analiz, Parselmouth aracılığıyla Python akışına entegre edilmiştir (Jadoul vd. 2018; Boersma ve Weenink 2026).

Akustik ölçüm doğrudan nihai karar değildir. Formant çıkarımı fonem sınıfına, pencere uzunluğuna, konuşmacıya ve kayıt kalitesine bağlıdır. Bu nedenle atlas ölçümleri çalışma zamanında kalite kanıtı ve analiz adayı olarak kullanılır. Değerlendirme motoru, kalite kanıtı zayıf ya da kararsız olduğunda bunu kullanıcıya dönük ayrı bir karar etiketi olarak değil, status/score gerekçesi ve analiz izi içinde raporlar. Bu seçim, MFCC-GMM tabanlı klasik telaffuz puanlama yaklaşımlarıyla (Witt ve Young 2000; Neumeyer vd. 2000; Hu vd. 2015) modern öz denetimli temsil tabanlı yaklaşımları aynı çalışma zamanında birleştirme imkânı verir.

2.5. Türkçe Fonetik Arka Plan

Türkçe fonetik yapısı, otomatik telaffuz değerlendirmesi açısından hem avantajlar hem zorluklar sunar. Türkçe ünlü sistemi sekiz temel fonemden oluşur: dört art (a, ı, o, u) ve dört ön (e, i, œ, y) ünlü. Bu ünlüler, F1 (açıklık-kapalılık) ve F2 (ön-art) formant frekansları ile ayırt edilir. Art ünlüler [a, ı, o, u] F2 değerlerinde daha düşük, ön ünlüler [e, i, œ, y] ise F2 değerlerinde daha yüksek konumlanır (Demircan 1996; Selen 1979). Türkçede ünlü uyumu, eklerdeki ünlülerin kök ünlüsüne göre ön/art ve düz/yuvarlak özelliklerini paylaşmasını gerektirir; bu, hem G2P'de hem de akustik modelde yapısal bir kısıt olarak ele alınabilir.

Ünlü uzunluğu, Türkçede hem alıntı sözcüklerde (circumflex işaretli â, î, û) hem fonolojik süreçlerden (coda yumuşak g uzatması, intervokalik h zayıflaması) kaynaklanır. Formant uzayında uzun ve kısa ünlüler büyük ölçüde örtüşür; ayırt edici sinyal süre (duration) kanalında bulunur. Bu nedenle CTC dağılımında uzun ünlüler kısa karşılıklarından ayrı atomik token olarak temsil edilmiştir; bu tercih, CTC collapse adımıyla süre bilgisinin kaybolmasını önler.

Türkçe ünsüz sistemi temel olarak patlayıcılar (p, b, t, d, k, g), affrikatlar (tʃ, dʒ), sürtünmeliler (f, v, s, z, ʃ, ʒ, h), genizsil ünsüzler (m, n), yanal ünsüz (l), titreşimli ünsüz (r) ve glide (j) sınıflarını içerir. Bu tezin hedef etiket envanteri, temel ünsüzlere ek olarak /ç, ɟ, ɲ, ɺ, β, β/ gibi bağlamsal allofonları ve /pʰ, tʰ, kʰ, cʰ, ɽ/ gibi pedagojik allofonları ayrı etiket olarak tutar. Patlayıcılar ötümlü-ötümsüz kontrastıyla ayrılırken, /k, g/ fonemleri ön ünlülerle

komşulukta palatalize olarak /c, ɟ/’ye dönüşür. /l/ fonemi iki allofona sahiptir: ön ünlülerle “clear” [l], art ünlülerle “dark” [ɫ]. Bu allofonik ayrım, F2 formant değerinde belirgin fark yaratır ve atlas katmanında ayırt edilebilir sinyal taşır (Göksel ve Kerslake 2005; Kornfilt 1997).

Formant analizi, ünlü tanıma ve kontrast değerlendirmesi için temel akustik ölçüm yöntemidir. F1 formantı ünlü açıklığıyla (düşük F1 = kapalı ünlü), F2 formantı ünlünün ön-art konumuyla (yüksek F2 = ön ünlü) ilişkilidir (Ladefoged ve Johnson 2005). Praat tabanlı formant çıkarımı (Boersma ve Weenink 2026), LPC (Linear Predictive Coding) analiziyle formant frekanslarını tahmin eder; ancak formant çıkarımı pencere uzunluğuna, konuşmacı vokaline ve kayıt kalitesine duyarlıdır. Bu nedenle bu tezde formant ölçümleri atlas katmanında özellikle ünlü kalite kanıtı olarak kullanılır, ancak tek karar kaynağı değildir; GMM log-yoğunluk quantile-rank dönüşümü kullanıcı statüsünü değil, analiz izi ve açıklayıcı kanalı destekler.

2.6. Telaffuz Değerlendirme Literatürü

Otomatik telaffuz değerlendirme literatürü, fonem düzeyi puanlama, yanlış telaffuz tespiti ve çok boyutlu geri bildirim yaklaşımlarını içerir. İlk eksen, beklenen fonemin akustik destek düzeyini Goodness of Pronunciation (GOP) puanıyla ölçen çalışmalardır; bu çizgi etkileşimli dil öğrenme sistemlerinde fonem düzeyi geri bildirim üretilebileceğini göstermiştir (Witt ve Young 2000; Neumeyer vd. 2000; Hu vd. 2015). İkinci eksen, yanlış telaffuz tespitini hata türü tanısıyla ayıran MDD çalışmalarıdır; posterior temelli, CTC temelli ve transformer tabanlı yaklaşımlar bu problemi doğrudan hedeflemiştir (Harrison vd. 2009; Li vd. 2017; Leung vd. 2019; Wu vd. 2021; Lin ve Wang 2021).

Üçüncü eksen, açık L2 corpus’ları ve çok görevli puanlama mimarileridir. L2-ARCTIC gibi açık L2 İngilizce corpus’ları (Zhao vd. 2018) ve speechocean762 puanlama corpus’u (Zhang vd. 2021), GOPT, MultiPA ve fonolojik özellik gözetimli yaklaşımlar gibi çok görevli mimarilerin ortaya çıkmasını mümkün kılmıştır (Gong vd. 2022; Chen vd. 2024; Shahin vd. 2025; Ye vd. 2022; Chhabra vd. 2024; Ziafat vd. 2021; Jiang 2024).

Güncel çalışmalar, tek bir global skor yerine fonem, sözcük ve cümle düzeyinde çoklu kanıt kullanımının önemini vurgular. Bu çoklu kanıt yaklaşımı, hem tanıma hem akustik ölçüm sinyallerini birlikte kullanan ve karar verme aşamasını ayrı bir politika katmanına devreden bir tasarımı haklı çıkarır. Bu tezdeki telaffuz değerlendirme sistemi de aynı genel ilkeye dayanır; ancak Türkçeye özgü hedef envanter, atlas referansı ve ham analiz adaylarını sınırlayan yetki politikasıyla açıklanabilir bir çalışma zamanı olarak uygulanır. Açıklanabilirlik ve güven kalibrasyonu literatürü (Doshi-Velez ve Kim 2017; Lipton 2018; Guo vd. 2017), sistemin kesin

hata bildirimi ile temkinli puanlama arasındaki ayrımı ölçülebilir kılmasının teorik dayanağıdır. Türkçe konuşma teknolojisi tarafında ise erken corpus ve ASR çalışmaları (Salor vd. 2002; Sak vd. 2012; Tombaloğlu ve Erdem 2016) ve Türkçe öğretiminde diksiyon/vurgu üretimine odaklanan saha çalışmaları (Akdoğan 2024; Gülen 2018; Erdem Nas ve Akbulut 2021; Artuner 1994) bu çalışmanın yerel bağlamını oluşturur.

2.7. Pedagojik Güvenlik

Telaffuz geri bildirimi asimetrik risk taşır. Doğru üretimi yanlış diye işaretlemek kullanıcının öğrenmesini bozabilir; yanlış üretimi kaçırmak da hatayı pekiştirebilir. Bu nedenle değerlendirme sisteminin yalnızca yüksek detection hedeflemesi yeterli değildir. Sert yanlış-alarm oranı, hedef hata konumunda precision ve belirsizlik oranı birlikte izlenmelidir. CAPT literatürü de teknolojik tasarımın pedagojik amaçla birlikte düşünülmesi gerektiğini, otomatik geri bildirimin doğru, kişiselleştirilmiş ve kullanıcı tarafından anlaşılabilir olmasının ayrı bir problem olduğunu vurgular (Rogerson-Revell 2021; Amrate ve Tsai 2024). Modern sinir ağı sınıflandırıcılarının kalibrasyon literatürü ise model güveninin doğrudan kullanıcı uyarısına dönüştürülmemesi gerektiğini ve sıcaklık ölçeklemesi ile izotonik regresyon gibi sonradan kalibrasyon yöntemlerinin pedagojik aşamadan önce uygulanması gerektiğini vurgular (Guo vd. 2017). Açıklanabilirlik bağlamında modelin yalnızca “yanlış” demesi yerine “hangi fonemin, neye, ne kadar kanıtla” değiştiğini bildirmesi tercih edilir (Doshi-Velez ve Kim 2017; Lipton 2018).

Bu tezde kullanıcıya dönük çıktı, correct, incorrect, missing ve extra statüleri ile sürekli fonem skorlarından oluşur. incorrect ve missing hedef fonem düzeyinde işaretlenir; extra ise hedef yanlış-pozitif sayılmadan sözcük skoruna ceza olarak yansır. Yetki tablosu, her hedef-alternatif fonem çifti için hangi akustik analiz adayının ham wav2vec gözlemini değiştirebileceğini sınırlar; tablo ayrı bir kullanıcı etiket sözlüğü tanımlamaz. Böylece sistem tanıyıcı çıktısını doğrudan öğretmen otoritesi gibi sunmak yerine, fonem düzeyinde açıklanabilir ama temkinli status/score geri bildirimi üretir. Bu temkin, kullanıcı mesajı tasarımında da korunmalıdır: modelin kanıtı zayıf olduğunda “yanlış yaptınız” yerine “bu hedef fonem için kanıt zayıf; tekrar deneyin veya öğretmen kontrolü gerekir” gibi belirsizliği açık eden ifadeler tercih edilmelidir.

2.8. Bu Tezin Konumu

Bu çalışma, Türkçe telaffuz değerlendirmesini dört parçalı bir problem olarak konumlandırır: hedef fonem dizisinin güvenilir üretimi, konuşma sinyalinden fonem kanıtı çıkarımı, atlas tabanlı akustik kalite değerlendirmesi ve güvenlik odaklı status/score üretimi. Bu ayrım, “tanıma başarısı” ile “geri bildirim güvenliği”nin aynı şey olmadığını operasyonel hale getirir. Türkçenin yapısal özellikleri (yüksek yazım-sesletim tutarlılığı + sınırlı sayıda fonolojik

istisna kümesi + G2P hedefinde temsil edilen vurgu kuralları) kural tabanlı bir G2P hattını uygulanabilir kılar; çok dilli öz denetimli akustik modellerin ulaşılabilirliği fonem tanıma için güçlü bir temel sağlar; geniş Türkçe konuşma verisinin Common Voice + ISSAI + sesli kitap kaynaklarıyla erişilebilir olması istatistiksel olarak anlamlı bir atlas oluşturmaya izin verir; ve pedagojik kullanım riski, bu üç kanalın çıktısını ağırlıklı ortalama da eritmek yerine ham analiz adaylarını sınırlayan, nihai kullanıcı çıktısını ise hedef-gözlem status/score hizalamasında tutan bir politika gerektirir. Tezin teknik tasarımı bu dört bileşenin her birini ayrı ayrı doğrulanabilir kılarak hem akademik incelemeye hem de canlı sistem geliştirmeye uygun bir araştırma omurgası sunmayı hedefler.

3. Yöntem

3.1. Araştırma Tasarımı

Bu çalışma, Türkçe telaffuz hedefi üreten ve konuşma kaydını bu hedefe göre açıklanabilir biçimde değerlendiren, fonem düzeyinde durum ve sürekli fonetik mesafe skoru üreten bir telaffuz değerlendirme sistemi geliştirmektedir. Sistem bir sözcük tanıyıcı olarak değil, verilen hedef fonem dizisi için “kayıtta beklenen fonem kimliği destekleniyor mu?” ve “bu üretim akustik olarak ne kadar güvenilir?” sorularını yanıtlayan bir değerlendirme katmanı olarak tasarlanmıştır.

Yöntem dört bileşenden oluşur: Türkçeye özgü grafem-fonem dönüşümü, fonem düzeyinde CTC akustik model, fonem atlasından türetilen akustik referans modeli ve çalışma zamanı status/score motoru. Bu bileşenler aynı 49 birimli IPA tabanlı hedef etiket envanterini paylaşır. G2P modülü hedef fonem dizisini üretir; wav2vec 2.0 (Baevski vd. 2020) tabanlı model kayıttan fonem olasılıkları ve serbest çözümleme çıkarır; atlas tabanlı referans modeli özellikle ünlülerde akustik tipiklik ve uzunluk ipuçlarını ölçer; çalışma zamanı motoru ise hedef dizi ile analiz edilmiş gözlemi hizalayarak hedef satırları için status, sürekli score, quality ve length, hedef dışı gözlemler için ise extra satırları üretir. Bu hesaplama katmanı demo arayüzü ve doğrulama scriptlerinden aynı prototip servis yolu üzerinden çağrılmıştır; servis ayrıntısı tezin ana katkısı değil, yöntemin uçtan uca aynı kod yoluyla sınanmasını sağlayan uygulama katmanıdır.

3.2. Veri Kaynakları ve Bölme Protokolü

Akustik model eğitimi ve referans atlası için üç açık Türkçe konuşma kaynağı kullanılmıştır: Mozilla Common Voice 24.0 Türkçe alt kümesi (kalabalık kaynaklı okuma konuşması), ISSAI Turkish Speech Corpus (stüdyo ortamında okuma konuşması) ve kamu malı Türkçe sesli kitap kayıtları (Ardila vd. 2020; Institute of Smart Systems and Artificial Intelligence (ISSAI), Nazarbayev University 2022). Tüm sesler 16 kHz mono PCM WAV biçimine dönüştürülmüş, transkriptler normalleştirilmiş ve kayıtlar SQLite tabanlı veri tabanında izlenmiştir. wav2vec eğitim manifestosuna yalnızca yayıncı doğrulamalı transkript taşıyan segmentler alınmış; Whisper ile transkribe edilen otomatik segmentler dışlanmıştır. Bu filtre sesli kitap kayıtlarını eğitim havuzu dışında tutar; sesli kitaplar yalnızca daha geniş kapsam gerektiren fonem atlası katmanına dahil edilmiştir. Sesli kitap kaynağı kamu malı olarak işaretlenmiş, tek anlatıcılı kitap bölümlerinden türetilen ve bölüm metniyle hizalanabilen kayıtlarla sınırlandırılmıştır; otomatik ya da zayıf hizalanmış segmentler CTC etiket eğitimine alınmamıştır. Bu seçim, CTC etiket kalitesinin hizalama kalitesinden bağımsız olmasını sağlar.

Konuşmacı sızıntısını azaltmak için aynı konuşmacıya ait kayıtların eğitim, doğrulama ve

test bölmelerinde birlikte yer alması engellenmiştir. Common Voice kayıtlarında her konuşmacının kimlik değeri SHA-1 ile hash'lenip 100 kovaya atanmış, kova numarası 90'ın altında olanlar eğitime, 90-94 arası doğrulamaya, 95-99 arası teste yönlendirilmiştir; bu deterministik 90/5/5 bölme Common Voice içinde aynı konuşmacının birden fazla bölmede görünmesini engeller. ISSAI TSC kayıtlarında konuşmacı kimliği dizin yapısından türetilmiş, açık konuşmacı kodu olmayan segmentler dosya bazlı hash'le kovaya atılmıştır; açık konuşmacı kodu taşımayan dosyalarda kalan sızıntı riski sınırlılık olarak kabul edilmiştir. Ham veri havuzu yaklaşık 344 saat ses içermektedir; 0,5 saniyeden kısa ve 15 saniyeden uzun kayıtlar wav2vec eğitiminden çıkarılmıştır (filtre sonrası 275,48 saat eğitim seti kalmıştır). Üst sınır toplu GPU OOM hatalarını engeller, alt sınır yetersiz fonetik içerikli segmentleri eler. Cümle düzeyinde tekilleştirme uygulanmış, normalleştirilmiş cümle metni bir kez bile doğrulama veya test bölmesinde geçen segmentler eğitim havuzundan çıkarılmıştır. Bu adım modelin belirli ezbercilik yoluyla doğrulama performansını şişirmesini önler.

Fonem atlası için kapsam daha geniş tutulmuştur. Atlas, 463.003 segment, 544,72 saat ses ve 22,4 milyon fonem penceresi üzerinden oluşturulmuştur. Sağlayıcı dağılımı ISSAI TSC için 218,23 saat, sesli kitaplar için 200,23 saat ve Common Voice için 126,26 saattir; manifest kapsamı %99,99 ve ortalama fonem güveni 0,8973'tür. Bu katmanda amaç model eğitmekten çok, her fonem için gözlenebilir akustik dağılımı ve özellik kapsamını belgelemektir. Bu nedenle hedef fonem, model gözlemi, hizalama zamanı, formant ölçümleri, süre ve hece belirginliği ayrı alanlar olarak saklanmıştır; konuşmacı/oturum üst verisi de kalibrasyon ve doğrulama sınırlarının atlas içinde sızmaması için ayrı tutulur. Eğitim verisindeki fonem sıklık dağılımı Şekil 1'de gösterilmiştir.

3.3. Grafem-Fonem Dönüşümü

G2P bileşeni Türkçe yazı biçiminden 49 birimli IPA tabanlı hedef etiket envanteri üretir. Kural tabanlı grafem-fonem dönüşüm yaklaşımı, Türkçenin yüksek yazım-sesletim düzenliliğinden yararlanır (Altınok 2016). Envanter sekiz kısa ünlü, sekiz atomik uzun ünlü, bir ünlü allofonu (/æ/), 20 temel ünsüz, yedi temel ünsüz allofonu (c, ʃ, ɲ, ɳ, ʈ, β, β̞), beş pedagojik allofon (p^h, t^h, k^h, c^h, ʈ̚) içerir; birincil vurgu işareti (ˈ) bu sayıma ek olarak suprasegmental düzeyde tutulur. Uzun ünlüler kısa ünlü ve uzunluk işaretine ayrılmamış, CTC dağılmasında atomik fonemler olarak temsil edilmiştir. Bu tercih, uzunluk bilgisinin CTC tekrar daraltma adımında kaybolmasını önlemek için yapılmıştır.

Kural hattı sabit sırayla çalışır. **Algoritma 1** hattın gerçek işleyişini özetler:

Algoritma 1. Kural tabanlı G2P.

```
Girdi: sözcük w
Çıktı: IPA fonem dizisi P
w ← NFC-normalize(w); baş/son noktalama kırp
eğer w kısaltma referansıysa (örn. TBMM):
    return referans IPA'sını ayrıştır # kural uygulanmaz
eğer w istisna sözlüğündeyse:
    P ← girdinin fonemleri
    istisna_tipi ← girdi.tip; M ← ∅
değilse:
    P ← akronimse harf-harf IPA, değilse grafem→IPA
    istisna_tipi ← ∅
    M ← morfolojik çözümleme(w) # kök, ekler, tür, özel ad?
# sıralı fonolojik kurallar (sıra bağımlılıkları korur)
P ← ünlü_uyumu(P)
P ← yumuşak_g(P, w, özel_ad?)
P ← palatalizasyon(P)
P ← lateral_allofonisi(P, w, istisna_tipi)
P ← v_allofonisi(P)
P ← n_yer_benzeşmesi(P)
P ← açık_e(P, w, istisna_tipi)
eğer pedagojik_allofonlar:
    P ← aspirasyon(P); P ← r_ötümsüzleşmesi(P)
P ← vurgu(P, w, istisna_tipi, M)
P ← vurgu_konumunu_kanönikleştir(P) # vurgu → hece başı
return P
```

Bu sıra, test edilen fonolojik bağımlılıkların doğru çözülebilmesini sağlar: örneğin nazal yer benzeşmesi ancak palatalizasyon kararından sonra yapılabilir, çünkü /n/'nin önündeki ünsüzün palatal mı yoksa velar mı olduğu bu adıma kadar belirlenmemiştir. Her kuralın tetiklendiği bağlam ve fonem dizisine etkisi Tablo 1'de özetlenmiştir; kurallar grafem-fonem eşleştirmesinin ardından Algoritma 1'deki sırayla uygulanır.

Tablo 1. G2P hattının grafem-fonem eşlemesi ve kurallarının tetikleyici bağlamı ile etkisi.

Grafem → IPA eşlemesi: Tetikleyen bağlam: Her harf (bağımsız); Etki: Türkçe yazımın bire bir ses karşılığını üretir; sonraki kuralların girdisi olan temel fonem dizisini kurar

Morfolojik çözümleme: Tetikleyen bağlam: Kök + ek sınırları (sonlu-durum çözümleyici); Etki: Kök/ek yapısını ve özel-ad bilgisini vurgu ve ek-uyumu kararlarına aktarır

Ünlü uyumu: Tetikleyen bağlam: Son kök ünlüsü; Etki: Ek ünlülerini artlık (a/e) ve dar-ünlü dörtlüsü (ı/i/u/ü) bakımından köke uyumlar

Yumuşak g (ğ): Tetikleyen bağlam: ğ'nin ünlü ve konum bağlamı; Etki: Altı yüzey: coda uzatma (dağ → /da:/), e sonrası [j], ön-ünlü glide, art-ünlü hiatus, özel-adda /g/, alıntıda silme

Palatalizasyon: Tetikleyen bağlam: /k, g/'nin ön ünlü komşuluğu; Etki: /k/ → /c/, /g/ → /ɟ/ (kedi → /'cedi/); circumflex'li alıntılar da tetikler

Lateral allofonisi: Tetikleyen bağlam: /l/'nin en yakın ünlüsü; Etki: Ön ünlü yanında açık [l], art ünlü yanında koyu [ɭ] (kulak → /ku'lak/); leksikal ince-l istisnaları (rol, gol, ...)

V allofonisi: Tetikleyen bağlam: /v/'nin yuvarlak ünlü komşuluğu; Etki: İki ünlü arasında yaklaşan [β], aksi hâlde bilabial sürtünmeli [β]

N yer benzeşmesi: Tetikleyen bağlam: /n/ + velar/palatal ünsüz öncesi; Etki: Velar önünde [ŋ], palatal önünde [ɲ] (palatalizasyon kararından sonra çözülür)

Açık /e/ (/æ/): Tetikleyen bağlam: Sonorant koda'lı kapalı hece; -mez/-maz eki; Etki: /e/ → /æ/ (ders → /dærs/); obstruent koda ve leksikal istisnalarda /e/ korunur (ekmek → /ek'mec/)

Aspirasyon (pedagojik): Tetikleyen bağlam: Hece-başı sessiz patlayıcı; Etki: /p, t, k, c/ → /p^h, t^h, k^h, c^h/

/r/ ötümsüzleşmesi (pedagojik): Tetikleyen bağlam: Sözcük-sonu veya sessiz ünsüz öncesi /r/; Etki: Daraltılmış-ötümsüz [r̥] (bir → /bir̥/)

Vurgu: Tetikleyen bağlam: Sözcük türü, ek sınıfı, yer-adı örüntüsü; Etki: Varsayılan sözcük-sonu vurgusu; ön-vurgulu/vurgu-çeken ekler ve yer adlarında Sezer cretic örüntüsü istisnaları

Vurgu kanonikleştirme: Tetikleyen bağlam: Yerleştirilmiş vurgu işareti; Etki: Vurgu işaretini hece başına taşır (IPA standardı)

Aşağıdaki tablo bu kuralların somut girdi-çıktı örneklerini verir:

Yumuşak g — coda uzatma: Örnek girdi: dağ; IPA çıktısı: /da:/

Yumuşak g — e sonrası [j]: Örnek girdi: değnek; IPA çıktısı: /dej'nec/

Yumuşak g - ön ünlü hiatus glide: Örnek girdi: değil; IPA çıktısı: /de'jil/

Yumuşak g - art ünlü hiatus: Örnek girdi: oğul; IPA çıktısı: /o.'ul/

Açık /e/ (/æ/): Örnek girdi: ders; IPA çıktısı: /dærs/

Açık /e/ korunan: Örnek girdi: ekmek; IPA çıktısı: /ek'mec/

k/g palatalizasyonu: Örnek girdi: kedi; IPA çıktısı: /'cedi/

Loan circumflex + palatalize: Örnek girdi: kâr; IPA çıktısı: /ca:ç/

Lateral allofonisi: Örnek girdi: kulak; IPA çıktısı: /ku'lak/

Sözcük-sonu /r/ ötümsüzleşmesi: Örnek girdi: bir; IPA çıktısı: /bir̥/

Yer adı Sezer stresi (cretic): Örnek girdi: Ankara; IPA çıktısı: /'ankara/

Bileşik ilk öge stresi: Örnek girdi: bilgisayar; IPA çıktısı: /'bilʃisajar̥/

Kural tabanlı yapı, Türkçenin yazım-sesletim düzenliliğinden yararlanır; alıntı sözcükler, yer adı vurgusu, bileşik sözcükler ve belirli uzun ünlüler için istisna sözlüğü kullanılır.

Bilinmeyen sözcüklerde sıra şudur: (1) istisna sözlüğü → (2) Starlang FSM tabanlı morfolojik çözümleme (Oflaz ve Saraçlar 2018) → (3) kural tabanlı dönüşüm → (4) karakter düzeyi geri çekilme (kısaltma sözcükleri için).

G2P doğrulaması üç bağımsız kaynakla yapılmıştır: Blind-75 uzman seti, Wiktionary IPA girdileri ve Montreal Forced Aligner Türkçe sözlüğü (McAuliffe vd. 2017). Bu kaynaklar aynı

şeyi ölçmez: Blind-75 Türkçeye özgü kural kapsamını manuel olarak izler, MFA sözlüğü geniş ölçekli segmental uyumu, Wiktionary ise dış kaynak heterojenliğine dayanıklılığı gösterir. Doğrulamada üç metrik raporlanır: sözcük düzeyinde tam eşleşme oranı, fonem düzeyinde edit-mesafe tabanlı Phoneme Error Rate ($PER = \text{Levenshtein mesafesi} / \text{referans fonem sayısı}$) ve sembol kategorileri arası segmental doğruluk. Vurgu işareti, segmental değerlendirmede fonem kimliğiyle karıştırılmaması için ayrıca izlenmiştir.


Fonem Atlası ve Akustik Özellikler

Atlas, değerlendirme sisteminin akustik referans katmanıdır. Her fonem örneği için süre, hizalama aralığı, F1–F2–F3 formantları, ünlüler için ek olarak hece içi F2 hareketi (`vowel_f2_movement_hz_per_ms`) ve hece düzeyinde belirginlik özellikleri çıkarılmıştır. Formant ölçümleri Parselmouth aracılığıyla Praat’a delege edilmiştir (Jadoul vd. 2018; Boersma ve Weenink 2026); yalnızca yeterli ötümlülük ve süre taşıyan pencereler kabul edilmiştir. 25 ms’den kısa fonemlerde formant ölçümü reddedilmiş, uç değerler atılmış ve fonem-başına kapsam istatistikleri saklanmıştır. Özellik kümesi fonem tipine göre değişir: ünlüler için dört boyutlu vektör (`f1_hz`, `f2_hz`, `f3_hz`, `vowel_f2_movement_hz_per_ms`) kullanılırken, ünsüzler için spektral centroid, bant genişliği, ötümlülük oranı, F2 geçiş eğimi, patlama merkezi frekansı ve VOT gibi tip-özgü türev özellikler çıkarılmıştır. Fonem başına kullanılan özellik adları model konfigürasyonunda saklanır.

Tek bir sabit formant penceresi yerine fonem-başına pencere politikası kullanılmıştır. 80, 100 ve 120 ms aday pencereler kapsam, karıştırılabilir çift ayrışması ve fonem-içi sıklık ölçütleriyle karşılaştırılmıştır. Her fonem için en yüksek birleşik skoru veren pencere seçilmiş, böylece çevrimdışı atlas çıkarımı ile çalışma zamanı ölçümü aynı ölçüm politikasını paylaşmıştır. Pencere seçim dağılımı 49 hedef etiketin 6’sı için 80 ms, 21’i için 100 ms ve 22’si için 120 ms olarak sabitlenmiştir.

Referans modeli, atlas özelliklerinden fonem-başına Gaussian karışım istatistikleri üretir. 49 birimli hedef etiket envanterinin 47’si için üç bileşenli bir karışım modeli eğitilmiş; en seyrek iki uzun ünlü olan /u:/ ve /y:/ için düşük örnek sayısı nedeniyle tek bileşenli fallback modeli tutulmuş ve kullanıcıya dönük kalite yorumunda sınırlı kullanılmıştır. Her bileşen ortalama vektörü (`mean`), ters kovaryans matrisi (`inv_cov`), log-determinant (`cov_log_det`) ve log ağırlık (`log_weight`) parametrelerini saklar. Her fonem için $n = 20.000$ ’e kadar atlas örneği kullanılmış; seyrek fonemlerde mevcut tüm örnekler değerlendirilmiştir. Ünlüler için özellik vektörü dört boyutlu (`f1_hz`, `f2_hz`, `f3_hz`, `vowel_f2_movement_hz_per_ms`) iken, ünsüzlerde türev özellikler boyut değişikliği gösterir. Eşik (`d_threshold`) fonem başına ayrı kalibre edilmiş olup, Mahalanobis benzeri uzaklık ölçüsüyle güvensiz gözlemleri “atypical” kategorisine taşır.

Çalışma zamanında log-yoğunluk, fonem-özgü quantile tablosuyla [0, 1] aralığına dönüştürülür; kullanıcıya dönük quality kanalı mevcut sürümde güvenilir formant ölçümü taşıyan ünlüler için raporlanır. Ünsüz özellikleri atlas kapsamını ve analiz adaylarını belgeleyen tanısal sinyal olarak tutulur, fakat bağımsız doğrulama olmadan nihai kullanıcı etiketine veya genel bir kalite hükmüne dönüştürülmez.



Şekil 1. Eğitim verisindeki fonem sıklık dağılımı. Sık ünlü ve ünsüzler yüz binlerce gözlemlerle temsil edilirken, uzun ünlüler ve bazı allofonlar daha seyrek kalmaktadır.

wav2vec Fonem-CTC Modeli

Akustik tanıma bileşeni için XLS-R-300M (24 katmanlı transformer, ~317M parametre) ve MMS-1B (48 katmanlı transformer, ~1B parametre) temelli iki fonem-CTC modeli aynı 54 birimli dağarcıkla eğitilmiştir (Babu vd. 2022; Pratap vd. 2024; Graves vd. 2006). Dağarcık <pad>, <unk>, 49 hedef etiketi, vurgu işareti, sözcük sınırı (<spc>) ve CTC blank biriminden oluşur; <blank> HuggingFace Wav2Vec2ForCTC başının CTC blank sembolü olarak ele alabilmesi için dağarcığın son tokenı olarak yerleştirilmiştir. Eski <sil> etiketi dağarcığa dahil edilmemiştir.

Eğitim manifestosu yayıncı doğrulamalı transkriptlerden oluşturulmuştur. Eğitim bölmesi 239.555 segment ve 275,48 saat; doğrulama bölmesi 14.793 segment ve 15,97 saat; test bölmesi 15.277 segment ve 18,65 saat içerir. Test kümesindeki PER hesabı, sözcük sınırı <spc> dışında 661.008 referans foneme dayanır. Test sağlayıcı dağılımı Common Voice 11.803 segment ve ISSAI TSC 3.474 segmenttir.

Her iki modelde özellik çıkarıcı 7-katmanlı evrişimli ön-uç dondurulmuş, transformer katmanları ve rastgele başlatılan doğrusal CTC başı Türkçe fonem görevine göre ince ayarlanmıştır. CTC başı XLS-R için 1.024 boyutundan, MMS-1B için 1.280 boyutundan 54 logite haritalanır. İki koşu aynı eğitim betiğini, aynı hedef dağarcığı, aynı veri bölmelerini, aynı etkin yığın boyutunu, aynı öğrenme oranını, aynı hassasiyet politikasını ve aynı kontrol noktası seçim ölçütünü paylaşır; warmup ve değerlendirme/kayıt aralığı gibi bazı zamanlama değerleri ise final kontrol noktalarındaki training_args.bin kayıtlarına göre koşu-özüdür:

Etkin yığın boyutu: 32 (XLS-R: cihaz başına $4 \times$ gradyan birikimi 8; MMS-1B: cihaz başına $8 \times$ gradyan birikimi 4)

Öğrenme oranı: 1×10^{-4} (lineer warmup $\rightarrow$ lineer decay)

Warmup: XLS-R: 500 adım; MMS-1B: 1.000 adım

Değerlendirme/kayıt aralığı: XLS-R: 400 adım; MMS-1B: 500 adım

Ağırlık çürümesi: 0

Hassasiyet: FP16

Erken durdurma: sabır 5 değerlendirme, eşik 0,001 PER

Kontrol noktası seçimi: en düşük doğrulama PER (load_best_model_at_end)

Tohum: 42

XLS-R epoch: 8 (~59.888 adım, ~20 GPU-saat)

MMS-1B epoch: 7,4 / 10 (~62.500 adım, ~37 GPU-saat)

Donanım: tek RTX 3090 (24 GB VRAM), AMD Ryzen 9 5900X, 64 GB DDR4; PyTorch 2.6.0+cu124. Toplam eğitim süresi yaklaşık 57 GPU-saattir. Gradyan kontrol noktası ve çoklu

DataLoader işçisi kullanımı tam bit-için-bit yeniden üretimi engeller; ancak aynı tohumla aynı donanımda tekrar eden PER farkı $\pm 0,2$ mertebesinde. Eğitim ve doğrulama PER eğrileri Şekil 4'te sunulmuştur.

Eğitim verisinin hazırlanması ve modelin ince ayarı **Algoritma 2**'de özetlenmiştir.

Algoritma 2. Eğitim verisi hazırlığı ve wav2vec ince ayarı.

```
# Manifest hazırlığı
S ← yayıncı doğrulamalı transkriptli segmentler # Whisper hariç
her segment için:
    16 kHz mono PCM'ye çevir; transkripti normalize et
    G2P ile hedef fonem dizisini üret
S'den süresi < 0,5 s veya > 15 s olan kayıtları çıkar
# Konuşmacı-sızıntısız bölme (Common Voice)
her konuşmacı için b ← SHA-1(kimlik) mod 100:
    b < 90 → train; 90–94 → dev; 95–99 → test # 90/5/5
dev/test'te geçen cümleleri train'den çıkar # tekilleştirme
# İnce ayar (XLS-R-300M ve MMS-1B, aynı yordam)
7 katmanlı evrişimli ön-ucu DONDUR
transformer katmanları + rastgele başlatılan CTC başını eğit
amaç: CTC kaybı; lr = 1e-4 (lineer warmup→decay); FP16
tohum = 42
her dev değerlendirmesinde PER ölç
erken durdurma (sabır 5, eşik 0,001 PER)
return en düşük dev PER'li kontrol noktası
```

Çalışma zamanı değerlendirme sistemi varsayılan olarak MMS-1B modelini kullanır; XLS-R-300M karşılaştırma ve tanı amaçlı alternatif olarak tutulur. Model çıktısı iki biçimde değerlendirmeye girer: tüm kayıt için serbest CTC çözümleme ve bu çözümlemeden türetilen zaman/posterior kanıtı. Çalışma zamanı, hedef fonemleri önce bu serbest gözlem dizisiyle Wagner–Fischer / Needleman-Wunsch ailesindeki global edit hizalaması üzerinden eşleştirir (Needleman ve Wunsch 1970); correct, incorrect, missing ve extra statüleri bu hedef-gözlem hizalamasından doğar. Bu hizalama aşamasında eşleşme, ikame, eksilme ve ekleme ilişkileri klasik edit-mesafesiyle kurulur; fonetik yakınlık cezası daha sonra sürekli skor olarak (Algoritma 4) raporlanır, hizalamanın gap/ikame maliyetini yeniden tanımlamaz. Posterior ve atlas kanıtı statüyü doğrudan yeniden yazan ayrı bir forced-alignment kararı değil, hizalanmış satırların zaman aralığı, kalite ve süre kanallarını destekleyen yardımcı kanıttır.

Çalışma Zamanı Hizalama

Çalışma zamanı hizalaması, hedef fonem dizisini kaydın zaman eksenine zorla yerleştiren tek bir Viterbi yolu değildir. Kullanıcıya dönük status önce dizisel düzeyde hesaplanır: wav2vec serbest çözümlemesi CTC tekrar daraltma sonrasında gözlem dizisini verir, bu dizi G2P hedef dizisiyle edit-mesafesi hizalamasına sokulur; hedef satırları için eşleşme, ikame veya eksilme, hedefte bulunmayan gözlemler için ise fazlalık ilişkisi çıkarılır. Zaman aralıkları ise serbest çözümlemedeki token süreleri ve posterior yoğunluklarından türetilir; bu aralıklar kalite ve uzunluk ölçümlerinin penceresini belirler. Hedef-gözlem hizalaması ve status üretimi **Algoritma 3**'te verilmiştir.

Algoritma 3. Hedef-gözlem hizalaması ve status türetimi.

```
Girdi: hedef dizi E[1..n], gözlem dizisi O[1..m] # 0: serbest CTC
Çıktı: hizalı satırlar; status ∈ {correct, incorrect,
      missing, extra}
# dp[i,j] = (maliyet, eşleşme): maliyeti MINİMİZE et,
#           eşitlikte eşleşmeyi MAKSİMİZE et
dp[i,0] ← (i,0) [missing]; dp[0,j] ← (j,0) [extra]
for i ← 1..n: for j ← 1..m:
  eğer E[i] = O[j]: köşe ← köşegen (maliyet, eşleşme+1), correct
  değilse: köşe ← köşegen (maliyet+1, eşleşme), incorrect
  dp[i,j] ← min(
    köşe,
    (dp[i-1,j].maliyet+1, ...) missing, # hedef gözlenmedi
    (dp[i,j-1].maliyet+1, ...) extra ) # hedef dışı gözlem
  anahtar: (maliyet ↑, sonra eşleşme ↓)
satırlar ← dp[n,m]'den geri-izle; sırayı düzelt
return satırlar # sürekli skor Algoritma 4 ile eklenir
```

Zorlamalı hizalama bu tezde tamamen dışlanmamıştır, ancak görevi farklıdır. Atlas oluşturma ve çevrimdışı akustik ölçümlerde Montreal Forced Aligner ve hedef-kışullu zamanlama yöntemleri fonem pencerelerini tabanlamak için kullanılmıştır. Canlı değerlendirme statüsü ise hedefe kışullu forced alignment sonucunu kullanıcı kararı gibi kullanmaz; düşük genlikli, kısa veya kararsız üretimler serbest çözümleme gözlemi ve hedef-gözlem hizalaması üzerinden yorumlanır. Bu ayırım, doğal konuşmadaki belirsizliği hedef diziyi zorla kayda oturttarak gizlememek için gereklidir.

Status Tabanlı Değerlendirme Mimarisi

Değerlendirme motoru her kayıt için hedef fonem dizisi ve 16 kHz mono ses dosyası alır. Çıktı tek bir karar etiketine indirgenmez; çalışma zamanı boru hattını açıkça yansıtan dört blokla temsil edilir:

target: G2P tarafından üretilen kanonik hedef metin ve fonem dizisi

wav2vec: Serbest CTC çözümleme, zamanlı fonemler ve posterior adayları

analysis: Akustik analizden sonra düzeltilmiş gözlem dizisi ve ham-gözlem düzeltme kayıtları

result: Hedef-gözlem hizalaması, fonem statüleri, skorlar ve özet metrikler

Ana kullanıcı ve doğrulama sözleşmesi fonem-düzeyi sonuç tablosudur. Her satırda beklenen ve gözlenen fonem, status, sürekli score ve gerekçesi, ayrık quality ve length kanalları ile zamanlama bilgisi bulunur. status değeri dört sınıftan biridir: correct hedef fonemin desteklendiğini, incorrect hedef fonemin başka bir analiz fonemine hizalandığını, missing hedef fonemin gözlenmediğini, extra ise hedefte bulunmayan ek bir gözlem olduğunu belirtir. Arayüze dönük durum, mevcut sürümde bu status ile aynıdır.

Fonem skoru, fonetik mesafe skoru fonksiyonuyla hesaplanır (**Algoritma 4**). Tam eşleşme 1,0 üretir; ünlülerde yükseklik, artlık, yuvarlaklık ve uzunluk; ünsüzlerde yer, biçim, ötümlülük, aspirasyon ve ikincil artikülasyon farkları dereceli cezalara dönüştürülür. Böylece

sistem yalnız “doğru/yanlış” sınıflaması yapmaz; hedefe ne kadar fonetik yakın bir üretim duyulduğunu [0,1] aralığında puanlar. Sözcük skoru hedef fonem satırlarının ortalama skorundan ve extra satırları için uygulanan ek-gözlem cezasından türetilir; skor sürümü phonetic-distance-v1 olarak etiketlenir.

Algoritma 4. Fonetik mesafe skoru.

```
Girdi: hedef fonem t, duyulan fonem h
      (+ ops. süre ve çift-kontrast kanıtı)
Çıktı: skor  $\in [0,1]$ 
eğer t yok  $\rightarrow$  return 0 (extra)
eğer h yok  $\rightarrow$  return 0 (missing)
eğer h = t  $\rightarrow$  return 1 # tam eşleşme: tam kredi
eğer sınıf(t)  $\neq$  sınıf(h):
    s  $\leftarrow$  0,05 # ünlü  $\leftrightarrow$  ünsüz
değilse eğer ikisi de ünlü:
    ceza  $\leftarrow$  min(0,24, 0,12 $\cdot$ |yükseklik(t) - yükseklik(h)|)
    artlık farklı  $\rightarrow$  ceza += 0,20
    yuvarlaklık farklı  $\rightarrow$  ceza += 0,16
    uzunluk farklı  $\rightarrow$  ceza += 0,24
    s  $\leftarrow$  max(0,30, 1 - ceza)
değilse (ikisi de ünsüz):
    ceza  $\leftarrow$  biçim(0,20-0,46) + yer(0,12-0,42)
    + ötümlülük(0,12/0,17) + aspirasyon(0,10) + ikincil(0,07)
    s  $\leftarrow$  max(0,12, 1 - ceza)
# yumuşak, kimliği ezmeyen düzeltmeler:
güvenilir süre kanıtı uzunluğu destekler  $\rightarrow$  s  $\leftarrow$  max(s, 0,90)
güvenilir süre kanıtı uzunluğu çürütür  $\rightarrow$  s  $\leftarrow$  min(s, 0,58)
kalibre dedektör hedefi/gözlemi destekler  $\rightarrow$  s  $\leftarrow$  s  $\pm$  0,05-0,07
return clamp(s, 0, 1)
```

Akustik analiz katmanı, wav2vec serbest çözümlemesini körü körüne kabul etmez. Fonem atlasından gelen GMM kalite kanıtı, süre kanalı ve kontrast-özgü ölçümler analiz adayları üretir. Yetki tablosu bu aşamada çift yönlü kontrast politikası olarak kullanılır: bir akustik adayın ham wav2vec gözlemini değiştirebilmesi için ilgili kontrastın yetkili ve güvenilir olması gerekir. Bu tablo kullanıcıya dönük nihai etiket üretmez; yalnızca hedef-gözlem hizalamasından önceki analiz izinde kaydedilen ham-gözlem düzeltmelerini sınırlar. Tablo, 49 fonemli envanterin tüm yönlü (kendisi hariç) kontrast çiftleri — 2.352 satır — üzerinde tanımlanır; her satır kontrast-özgü doğal yanlış-pozitif gözlemini, örnek kapsamını ve izin gerekçesini saklar. Bu satırlardan yalnızca 195’i, çevrimdışı kalibre edilmiş bir çift-kontrast dedektörüyle ham gözlemi değiştirmeye yetkili (sert geçersiz kılma) kontrastlardır; geri kalan satırlar yalnızca kalite kanıtıyla sınırlı kalır ya da hiç override iznine açılmaz. Tablonun inşası **Algoritma 5’te** özetlenmiştir.

Algoritma 5. Kontrast yetki tablosunun inşası.

```
Girdi: 49 fonem envanteri
       atlas örnekleri (konuşmacı-ayrık train/dev/test)
Çıktı: yönlü (hedef → alternatif) kontrast yetki tablosu
her (hedef t, alternatif a), t ≠ a için: # 49×48 = 2.352 çift
  F ← t ve a'nın paylaştığı sınıf-özgü atlas özellikleri
  en_iyi ← ∅
  F'nin en çok 3 boyutlu alt kümeleri için:
    train'de t ile a'yı ayıran doğrusal izdüşüm öğren
    eşiği dev'de hedef-FP ≤ %2 olacak şekilde seç
    eğer dev_FP ≤ %2 ∧ test_FP ≤ %2
      ∧ dev_recall ≥ %5 ∧ test_recall ≥ %5 ∧ marj > 0:
        en_iyi ← recall daha iyiye bu dedektörle güncelle
    eğer en_iyi ≠ ∅: policy ← hard_override # ayrılabilir
    değilse eğer aynı/uyumlu sınıf: policy ← quality_only
    değilse: policy ← no_override
    tabloya (t, a, policy, en_iyi) ekle
# 2.352 satırın 195'i hard_override yetkisi taşır
return tablo
```

Kalite puanı, fonem-başına atlas referans modeliyle çalışma zamanı özelliklerinin karşılaştırılmasına dayanır. Ölçülen özellik vektörü x için karışım log-yoğunluğu hesaplanır:

$$\log p(x) = \log \sum_{k=1}^3 \pi_k N(x; \mu_k, \Sigma_k)$$

Bu log-yoğunluk, fonem-özgü quantile tablosunda hangi yüzde dilime düştüğüne göre [0, 1] aralığına eşlenir. Ham analiz izinde bazı ünsüzler için de quality_score bulunabilir; ancak mevcut kullanıcıya dönük sürümde kalite yorumu özellikle ünlü fonemlerde doğrulanmış kabul edilir. Ünsüz akustik özellikleri araştırma ve analiz izi kapsamında tutulur, çünkü bu özelliklerin yanlış-pozitif etkisi iki konuşmacılı doğrulama setinde bağımsız bir kullanıcı kararı olarak güvenilir biçimde kalibre edilmemiştir. Olasılık kalibrasyonunun gerekliliği, modern sinir ağlarının iyi kalibre edilmemiş çıktıları için kapsamlı biçimde gösterilmiştir (Guo vd. 2017); bu tezde söz konusu motivasyon, GMM log-yoğunluğunun fonem-özgü quantile tablosuyla normalleştirilmesi yoluyla karşılanır.

Uzunluk kanalı karar kapısı değildir. Her fonem için medyan süre ve bir ölçek değeri saklanır; çalışma zamanı süresinin medyandan farkı ölçeğe normalleştirilerek yumuşak bir uzunluk skoru, açıklayıcı bir not (kısa/normal/uzun) ve standartlaştırılmış bir sapma değeri üretilir. Bu bilgi özellikle uzun ünlülerde ve süreye duyarlı üretimlerde açıklama sağlar, fakat iyi artiküle edilmiş doğal süre değişkenliğini doğrudan yanlış etikete dönüştürmez.

Değerlendirme Seti

Çalışma zamanı değerlendirmesi, iki anadili Türkçe konuşmacıdan oluşan stüdyo seti üzerinde yapılmıştır; konuşmacılar anonim olarak K1 ve K2 biçiminde gösterilir. Her konuşmacı 75 istem üretmiştir; toplam 150 nihai kayıt değerlendirilmiştir. Değerlendirme, kontrollü stüdyo okuması ve kasıtlı-hata tasarımıyla sınırlandırılmıştır; bu sınırlı ölçek, çalışmanın bilinçli olarak kabul ettiği bir kapsam kısıtıdır (bkz. Bölüm 5). Stüdyo oturumunda

belirgin okuma hatası, yanlış istem okuma ya da istenen kasıtlı üretimin açıkça yapılamaması durumunda konuşmacıdan aynı istemi yeniden okuması istenmiş ve metriklere yalnız seçilen nihai okuma alınmıştır. Bu yeniden okuma denemeleri ayrı bir dışlama sayacı olarak loglanmadığı için tez, kayıt dışlama oranı iddiası taşımaz; raporlanan tüm oranlar commit edilen 150 nihai kayıt ve 2.324 hedef fonem üzerinden hesaplanır. İstemler üç gruba ayrılır:

CTL: Kontrol cümleleri; doğal doğru üretimde işaretli yanlış-pozitif ölçümü

W_NAT: Doğal hedef telaffuz; normal cümlelerde işaretli yanlış-pozitif ölçümü

W_ERR: Kasıtlı yanlış hedef; beklenen hata konumunda yakalama ölçümü

W_ERR istemleri, sık ve pedagojik olarak anlamlı fonem çiftleri seçilerek tasarlanmıştır. Bu grupta 36 istem vardır; bazı kural kategorileri birden çok sözcükle temsil edilir. Metrik hesabında esas payda istem sayısı değil, konuşmacı başına 32 hedef hata konumu ve toplam 64 hedef hata konumudur. Konuşmacılardan doğru hedef yerine kasıtlı yanlış telaffuzu üretmeleri istenmiştir. Tasarlanmış yanlış IPA hedefi, kanonik hedefle kasıtlı yanlış üretim arasındaki fonem konumlarını belirlemek için kullanılmıştır; örneğin görüyorum isteminde ön yuvarlak ünlülerin arka ünlülere çevrilmesi (/æ, y/ → /o, u/) tasarlanmış hedef sapma olarak kaydedilmiştir. Bu hedef sapma konumları metrik paydasına dönüştürülür; böylece incorrect veya missing olarak işaretlenen fonemlerin gerçekten hedeflenen hata konumuna denk gelip gelmediği ölçülebilmektedir. Doğrulama, demo arayüzle aynı çalışma zamanı servis yolunu kullanmıştır.

Metrikler

Doğal doğru gruplarda temel güvenlik metriği işaretli yanlış-pozitif oranıdır. Bir hedef fonem status $\in \{\text{incorrect, missing}\}$ ise işaretli sayılır; extra hedef fonem satırı olmadığı için bu orana girmez, fakat sözcük skorundaki extra_penalty ile cezalandırılır:

$$\text{flagged FP} = \frac{\text{incorrect} + \text{missing hedef fonem sayısı}}{\text{toplam hedef fonem sayısı}}$$

Oranlar küçük örnekli konuşmacı alt kümelerinde geniş belirsizlik taşıdığından, temel oranlar için Wilson %95 güven aralığı da yorumlanabilir (Wilson 1927).

W_ERR grubunda iki metrik kullanılmıştır. Tespit oranı, hedeflenen yanlış konumların kaçında sistemin fonemi kabul etmeyip incorrect veya missing ürettiğini ölçer:

$$\text{detection} = \frac{\text{hedef hata konumunda işaretlenen fonem sayısı}}{\text{hedef hata konumu sayısı}}$$

Hata-konumu kesinliği ise tüm işaretli hedef fonemlerin içinde kaçının tasarlanmış hata konumuna denk geldiğini ölçer:

$$\text{precision-at-error} = \frac{\text{hedef hata konumunda işaretlenen fonem sayısı}}{\text{tüm işaretli hedef fonem sayısı}}$$

Bu ayrım önemlidir: bir sistem çok hata yakalayabilir fakat doğru konumları değil ilgisiz fonemleri suçluyorsa pedagojik olarak güvenli değildir. Bu nedenle bulgulara tespit, hata-konumu kesinliği, doğal konuşmadaki işaretli yanlış-pozitif ve ortalama fonem skoru birlikte

raporlanmıřtır. wav2vec tanıyıcısının kendisi için ayrıca tek model metrikleri raporlanır; Full IPA PER tüm 49 hedef etiketi ve vurgu işareti üzerinden hesaplanır, segmental PER ise vurguyu dışlar.

Uygulama ve Veri Eriřilebilirlięi

Bu bölümde tarif edilen bileřenlerin tümünün — kural tabanlı G2P motoru, wav2vec fonem-CTC eğitim ve deęerlendirme akışı, fonem atlası ve çalışma zamanı status/score motoru — referans uygulaması, benchmark ve doęrulama veri tabloları, konfigürasyonlar ve figür üretim betikleri açık depo olarak erişilebilir: <https://github.com/onesvat/telaffuz-yz>. Yukarıdaki algoritmalar bu uygulamadan türetilmiřtir ve metnin kendisinden bağımsız olarak yeniden geręeklenebilecek ayrıntıda verilmiřtir. Ham ses kayıtları, model kontrol noktaları ve büyük türev artefaktlar (atlas veri tabanı, eğitim manifestoları) deponun boyut politikası gereęi dışarıda tutulur; tezdeki nicel sonuçlar depodaki küçük tablolar ve özet raporlardan yeniden üretilebilir.

4. Bulgular

Bu bölüm sistemin dört bileşeninin her birini ayrı ayrı raporlar ve ardından çalışma zamanı değerlendirme motorunun iki anadili konuşmacılı stüdyo değerlendirmesini sunar. G2P bulguları hedef fonem dizisinin güvenilirliğini, atlas bulguları akustik referans katmanının kapsamını, wav2vec bulguları fonem tanıma performansını ve değerlendirme bulguları üç sinyalin pedagojik güvenliğe nasıl çevrildiğini gösterir.

4.1. Grafem-Fonem Dönüşüm Bulguları

G2P motoru üç bağımsız ölçekte değerlendirilmiştir: 75 sözcüklük kör uzman seti (Blind-75), Montreal Forced Aligner Türkçe sözlüğü ve Wiktionary IPA girdileri. Bu kaynaklar aynı şeyi ölçmez: Blind-75 seti Türkçeye özgü kural kapsamını manuel olarak izler, MFA sözlüğü geniş ölçekli segmental uyumu, Wiktionary ise dış kaynak heterojenliğine dayanıklılığı gösterir. Üç set arasında en kontrollü kaynak Blind-75'tir; uzman tarafından el ile etiketlenmiş olduğundan kural tabanlı grafem-fonem dönüşüm yaklaşımının (Altınok 2016) en kontrollü ölçüsü olarak ön plana çıkar. MFA ve Wiktionary, sözlük kullanım koşullarındaki sürtünmeyi ve farklı IPA notasyon geleneklerinin farkını ortaya koyar.

Blind-75 setinde motor 75 sözcüğün 68'inde tam eşleşme sağlamış, 472 hedef fonem üzerinde 7 edit hatasıyla $PER = 0,015$ elde etmiştir. Segmental sembol doğruluğu %98,52'dir. Kalan farklar rastgele dağılmamış; uzun ünlü gerektiren alıntı sözcükler, sözcük başı küme epentezi, yer adı/alıntı vurgu istisnaları ve morfolojik çözümleme sınırlarında yoğunlaşmıştır. Bu hata yapısı kural tabanlı yaklaşımın doğal sınırını gösterir: alıntı sözcüklerin uzun ünlü kalıbı ve özel ad vurgusu istisna sözlüğü olmadan kural başına çözülemez.

MFA Türkçe sözlüğünde 41.373 sözcük değerlendirilmiş, 33.807 tam eşleşme ve $PER = 0,032$ elde edilmiştir. Wiktionary kaynağında 14.015 puanlanan sözcükte $PER = 0,118$ bulunmuştur. Wiktionary sonucunun daha düşük olması, özellikle vurgu, hece sınırı, akronim okunuşu ve kaynakta kullanılan IPA sembol çeşitliliğinden kaynaklanmaktadır; örneğin Wiktionary'nin uzun ünlü için kısa ünlü + üst nokta notasyonu kullanması, atomik uzun ünlü hedef envanteriyle birebir eşleşmez.

Kaynak	Sözcük	Tam eşleşme	PER	Not
Blind-75	75	68 (%90,7)	0,015	Uzman kontrollü set
MFA Türkçe	41.373	33.807 (%81,7)	0,032	Geniş sözlük karşılaştırması
Wiktionary	14.015	—	0,118	Heterojen dış kaynak

Bu sonuçlar, hedef fonem dizisinin değerlendirme sistemi için yeterince güvenilir bir başlangıç noktası sağladığını göstermektedir. G2P hataları tamamen ortadan kalkmamış olsa da, hatalar belirli sözlüksel istisna sınıflarında toplanmaktadır. Bu hata profili, değerlendirme hattında G2P çıktısının doğrudan CTC etiket dizisine ve çalışma zamanı hedef dizisine

aktarılmasını mümkün kılar; yine de G2P'deki kalan hatalar çalışma zamanı değerlendirmesine doğrudan taşınabileceği için istisna sözlüğü güncellemesi sistem bakımının parçası olarak kalır.

4.2. Fonem Atlası Bulguları

Fonem atlası 463.003 segment, 544,72 saat ses ve 22.403.990 fonem penceresiyle oluşturulmuştur. Manifest kapsamı %99,99, ortalama fonem güveni 0,8973 olarak ölçülmüştür. Formant ölçümleri Parselmouth aracılığıyla Praat'a delege edilmiştir (Jadoul vd. 2018; Boersma ve Weenink 2026). Sağlayıcı dağılımı ISSAI TSC için 218,23 saat, sesli kitaplar için 200,23 saat ve Common Voice için 126,26 saattir. Üç kaynaklı yapı, hem stüdyo kalitesinde (ISSAI), hem kalabalık kaynaklı (Common Voice), hem de geniş süre dağılımı sağlayan (sesli kitap) verileri birleştirilerek atlas dağılımının tek bir akustik koşula sıkışmasını önler.

Atlas, temel kısa ünlü ve ünsüzlerde yüksek örnek sayısına ulaşmıştır. /a/, /e/, /i/, /n/, /ɾ/ ve /s/ gibi sık fonemlerde yüz binlerce ya da milyonlarca gözlem vardır; örneğin GMM eğitimi için $n = 20.000$ örnek limiti her sık fonemde kolaylıkla doldurulmuştur. Uzun ünlüler ve bazı pedagojik allofonlar (/æ:/, /y:/, /i:/) daha seyrek kalmıştır; bu durum değerlendirme sisteminde uzunluk kanalının yumuşak tanısal sinyal olarak tutulmasının ve analiz yetki tablosunda bu fonemlerin override iznine açılmamasının ana gerekçesidir. Aşağıdaki tablo, atlasta her fonem için gözlenen örneklem sayısını verir (47 etiket); düşük kapsamlı /u:/ ve /y:/ tablo dışında tutulmuş ve GMM referansında tek bileşenli fallback olarak ele alınmıştır.

a: 126.364

i: 90.719

e: 77.033

n: 71.672

d: 53.113

u: 51.773

r: 49.128

m: 43.747

j: 40.694

u: 37.842

s: 35.007

ɫ: 34.208

b: 33.156

l: 30.765
ɫ̥: 30.056
o: 27.666
tʰ: 26.528
æ: 21.076
y: 20.037
kʰ: 18.284
ʃ: 18.148
z: 16.859
k: 14.819
h: 12.741
tʃ: 11.871
ʒ: 11.075
cʰ: 10.751
t: 9.988
v: 9.840
dʒ: 9.235
œ: 8.020
a: 6.789
c: 6.044
f: 5.549
pʰ: 4.990
o: 4.070
p: 3.323
ɲ: 2.646
i: 1.881
œ: 1.872
g: 1.570
β: 849
u: 514

ɜ: 448

β: 335

ŋ: 304

e.: 103

Sık fonemlerde 20.000 örnek sınırı her zaman erişilirken, tablodaki en seyrek etiketlerde (/e:/ için 103, /ŋ/ için 304) mevcut tüm örnekler değerlendirilmiş, bu durumlarda kalite kanıtı belirsiz sayılmıştır. GMM referansında ise tabloya girmeyen /u:/ ve /y:/ düşük kapsam nedeniyle tek bileşenli fallback ile tutulmuştur. Atlas, fonem sınırlarını zorlamalı hizalayıcının çerçeve çözünürlüğü düzeyinde tabanlar (McAuliffe vd. 2017) (çerçeve kaydırmasının iki katı mertebesinde, yaklaşık 20 ms); bu nedenle referans dağılımı mutlak süreleri güvenilir biçimde ayrıştıramaz ve uzunluk kanalı status kapısı olarak değil, yalnızca yumuşak tanısal sinyal olarak kullanılır. Uzun-kısa ünlü ayrımının süreden değil tanıyıcı posterior'undan çözülmesi de bu kısıtın doğrudan sonucudur.


Formant pencere politikası deneyinde 49 hedef etiketin 6'sı için 80 ms, 21'i için 100 ms ve 22'si için 120 ms pencere seçilmiştir. Kısa pencereler özellikle hızlı hece içi formant geçişi olan açık ünlüler için kapsam-sıklık dengesinde üstündür; uzun pencereler ise patlayıcılar ve sürtünmelilerin gürültülü kuyrukları bastırarak daha kararlı bir formant ortalaması üretir.

80 ms: Fonem sayısı: 6; Örnekler: /æ/, /e/, /e:/, /a:/


100 ms: Fonem sayısı: 21; Örnekler: /a/, /i/, /o/, /u/, /ʊ/, /n/, /ɾ/

120 ms: Fonem sayısı: 22; Örnekler: /b/, /d/, /k/, /t/, /l/, /ʎ/, /v/, /ʃ/

Karıştırılabilir ünlü çiftlerinde formant ayrışması belirgindir. /e/ ile /æ/ ayrımında F1 farkı yaklaşık 186 Hz (436 Hz'e karşı 622 Hz), F2 farkı yaklaşık 277 Hz (1981 Hz'e karşı 1704 Hz) olarak ölçülmüştür. /i/ ile /ʊ/ ayrımında F2 farkı yaklaşık 479 Hz (2088 Hz'e karşı 1609 Hz) düzeyindedir. /l/ ile /ʎ/ ayrımında F2 farkı yaklaşık 560 Hz (1923 Hz'e karşı 1363 Hz) tanısal sinyal sağlamıştır (bkz. Şekil 2 ve Şekil 3). Buna karşılık uzun ünlülerin kısa karşılıklarından formantla ayrışması zayıftır; bu ayrım kalite puanından çok süre kanalında izlenmelidir. Bu bulgu, uzun-kısa ünlü kontrastlarında atlas ölçümünün ham tanıyıcı gözlemi doğrudan geçersiz kılan nihai karar kaynağı olarak kullanılmamasının deneysel gerekçesidir.



Şekil 2. Türkçe ünlü ve lateral seslerin atlas örnekleimine dayalı medyan F1/F2/F3 değerleri. Kısa ünlü çiftlerinin formant uzayında ayrıştığı, uzun karşılıklarının ise büyük ölçüde kısa öbeklerle örtüştüğü; lateral allofonlarının (/l/, /ɬ/) ise F2 ekseninde belirgin biçimde ayrıştığı görülmektedir. Uzunluk ayrımı bu nedenle süre kanalına bırakılmıştır.



Şekil 3. Türkçe ünlü uzayı (F1–F2 düzlemi). Ünlü üçgeninin köşe noktaları (a, i, u, ɨ, o, æ) ile açık /e/ (/æ/) konumu gösterilmektedir. Lateral allofonlarının (/l/) F2 eksenindeki kayması belirgindir.

4.3. wav2vec Fonem Tanıma Bulguları


XLS-R-300M (Babu vd. 2022) ve MMS-1B (Pratap vd. 2024) modelleri aynı 54 birimli fonem dağarcığı, aynı eğitim/dev/test bölmesi ve aynı eğitim betiğiyle eğitilmiştir. Her iki model de wav2vec 2.0 (Baevski vd. 2020) mimarisi üzerine CTC (Graves vd. 2006) başlığı ile ince ayarlanmıştır. Etkin yığın boyutu, öğrenme oranı, dondurulmuş özellik çıkarıcı, FP16 politikası, tohum ve en düşük doğrulama PER'e göre seçim ortak tutulmuş; cihaz başına yığın/gradyan birikimi, warmup ve değerlendirme-kayıt aralığı gibi zamanlama değerleri final kontrol noktası kayıtlarında koşuya özgü olarak saklanmıştır. Test kümesi 15.277 segment, 18,65 saat konuşma ve 661.008 referans fonem içermektedir. XLS-R-300M modeli 8 epoch sonunda Full IPA PER = %4,05 ve Segmental PER = %3,49 elde etmiştir. MMS-1B modeli 7,4 epoch sonunda Full IPA PER = %4,13 ve Segmental PER = %3,62 elde etmiştir. İki model arasındaki fark Full IPA PER'de yalnızca 0,08 yüzde puanıdır; ISSAI-TSC kaynak kümesinde her iki model aynı PER değerini (%4,41) paylaşmakta, fark yalnızca Common Voice kümesinden kaynaklanmaktadır (XLS-R-300M %3,88, MMS-1B %4,00). İki model yapısal olarak yakın performans sergilemektedir (Şekil 5).

Model	Epoch	Full IPA PER	Segmental PER
XLS-R-300M	8	%4,05	%3,49
MMS-1B	7,4	%4,13	%3,62


Bu sonuçlar iki noktayı gösterir. Birincisi, parametre sayısı bakımından üç kat büyük olan MMS-1B, daha küçük XLS-R-300M karşısında pratikte kayda değer bir kazanç üretmemektedir; her iki model de %4,1 bandında yaklaşmaktadır (0,08 puanlık fark model seçimini gerekçelendirmeyecek kadar küçüktür). Bu, Türkçe fonem tanıma için model seçiminin parametre sayısından çok eğitim protokolü ve dağarcık paylaşımı tarafından belirlendiğini gösterir; çalışma zamanı değerlendirme motoru MMS-1B'yi varsayılan olarak alırken XLS-R-300M karşılaştırma amaçlı yan yana tutulur. İkincisi, segmental PER'in Full IPA PER'den her iki modelde de yaklaşık 0,5 puan düşük olması, vurgu işaretinin tanıyıcı tarafından fonem kimliğinden daha az kararlı çözüldüğünü gösterir; bu bulgu, çalışma zamanında vurgu kararının tek başına tanıyıcı çıktısına bırakılmaması gerektiğine işaret eder.

Fonem sınıfı analizinde temel ünsüzler, nazaller, affrikatlar ve kısa ünlüler düşük hata oranı üretmiştir. En zayıf sınıflar uzun ünlüler ve bilabial varyantlardır. Uzun ünlüler özellikle kısa karşılıklarıyla karışmaktadır; aynı sözcüğün hem /a:/ hem /a/ olarak çözüldüğü kayıt çiftlerinde tanıyıcı kararı süreden çok hece-içi spektral ipuçlarına dayanmaktadır. Bu zayıflık yalnız akustik model kapasitesiyle açıklanamaz: Türkçedeki sözlüksel uzun ünlülerin önemli bölümü Arapça/Farsça alıntılardaki istisna davranışına dayanır ve yazıda çoğu zaman inceltme işaretiyle (â, î, û) gösterilir. Bu işaret hem telaffuzu hem anlamı ayrırabilir; örneğin kar “snow”, kâr ise “profit” anlamındadır. Ancak eğitim manifesti bu ortografik ipucunu seyrek taşır: Common Voice satırlarının yalnız 992/86.865'i (%1,14; 775/63.974 benzersiz transkript)


inceltme işareti içerirken ISSAI-TSC tarafında 182.760 satırın hiçbirinde bu işaret yoktur. Bu nedenle alıntı kökenli uzunluk çoğu durumda G2P istisna sözlüğüyle ve çalışma zamanında ayrıca ölçülen süre kanalıyla desteklenmelidir. Bu sonuç, çalışma zamanı değerlendirmesinde uzunluk bilgisinin ayrı bir kanal olarak tutulmasını ve status/score motorunun uzun ünlü kontrastlarında posterior ile süre/atlas kanıtını ayrı raporlamasını destekler (Şekil 8). Fonem sınıfı bazında PER kırılımı Şekil 6’da, varsayılan MMS-1B modelinin fonem başına PER dağılımı Şekil 7’de sunulmuştur; XLS-R-300M kırılımı ana metinde ayrı figür olarak yinelenmemiş, iki modelin karşılaştırması Şekil 5 içinde tutulmuştur.




Şekil 4. XLS-R-300M ve MMS-1B modellerinin eğitim ve doğrulama PER eğrileri. Her iki modelde de doğrulama PER’i monotonik biçimde düşmüş, MMS-1B 61.000. adımda en iyi kontrol noktasına ulaşmış, XLS-R 58.800. adımda kararlı dip değerini bulmuştur.




Şekil 5. Fonem bazında fonem hata oranı: XLS-R-300M (genel %4,05) ve MMS-1B (genel %4,13) karşılaştırması. İki model fonem düzeyinde benzer hata profili sergiler; en yüksek hata seyrek uzun ünlüler ve bilabial varyantlarda yoğunlaşır.



Şekil 6. Fonem sınıfı bazında PER kısıtlımı. Patlayıcılar, sürtünmeliler, nazaller ve kısa ünlüler düşük PER bandındayken uzun ünlüler ve pedagojik allofonlar (özellikle /β/, /β/ çifti) belirgin hata kaynağıdır.



Şekil 7. MMS-1B modelinin fonem başına PER dağılımı. Sık ünlü ve ünsüzler düşük hata bandında kalırken, seyrek uzun ünlüler ve bilabial varyantlar dağılımın yüksek-hata kuyruğunu oluşturur.




Şekil 8. Uzun ünlülerde fonem hata oranı: XLS-R-300M ve MMS-1B karşılaştırması. Her uzun ünlü için referans örnek sayısı (n) sütun üzerinde verilmiştir; tanıyıcı seyrek uzun ünlülerde (/e:/, /y:/, /w:/) belirgin biçimde daha yüksek hata üretir; bu durum uzunluk için süre kanalının ayrı tutulmasını desteklemektedir.

4.4. Stüdyo Değerlendirmesi

Önceki alt bölümler G2P hedef üretimini, atlas referansını ve wav2vec fonem tanımayı ayrı ayrı doğrulamıştır. Bu bölümde aynı bileşenlerin birleşik çalışma zamanı davranışı ölçülür: hedef dizinin üretilmesi, kaydın serbest CTC çözümlemesi, hedef-gözlem hizalaması ve fonem düzeyi status/score üretimi tek hat olarak değerlendirilir.

Değerlendirme motoru iki anadili konuşmacılı 150 kayıtlık stüdyo setinin tamamında çalıştırılmıştır. Değerlendirme varsayılan MMS-1B modeliyle yapılmış ve her kayıt için phonetic-distance-v1 sözleşmesine göre hedef fonem, analiz edilmiş gözlem, status, sürekli score, kalite ve uzunluk alanları üretilmiştir. Ham çalıştırma çıktıları yerel değerlendirme kayıtlarına, commit edilen özetler ise assessment raporlarına yazılmıştır.



Şekil 9. İki anadili konuşmacılı stüdyo değerlendirme setinin bileşimi. CTL, W_NAT ve W_ERR grupları arasındaki fonem dağılımı ve konuşmacı bazında istem sayıları gösterilmektedir.

Değerlendirme setinin istem bileşimi Şekil 9’da özetlenmiştir. Toplam hedef fonem sayısı CTL grubunda 454, W_NAT grubunda 1.498 ve W_ERR grubunda 372’dir. Doğal doğru gruplarda işaretli yanlış-pozitif oranı CTL için %5,29, W_NAT için %5,54’tür. Kasıtlı hata grubunda hedef hata yakalama oranı %65,62, precision-at-error değeri %53,85’tir. Wilson %95 güven aralıkları CTL yanlış-pozitif için %3,58–%7,75, W_NAT yanlış-pozitif için %4,49–%6,82, W_ERR tespiti için %53,40–%76,08 ve precision-at-error için %42,86–%64,47 aralığındadır. Burada “işaretli” satır, hedef fonemin incorrect veya missing durumunda olmasıdır; extra satırları hedef fonem olmadığı için bu paya girmez, fakat sözcük skorunu extra_penalty ile düşürür.

CTL: Hedef fonem: 454; Correct: 430; Incorrect: 18; Missing: 6; Extra: 1; İşaretli: 24; Ana metrik: işaretli yanlış-pozitif = %5,29

W_NAT: Hedef fonem: 1.498; Correct: 1.415; Incorrect: 63; Missing: 20; Extra: 10; İşaretli: 83; Ana metrik: işaretli yanlış-pozitif = %5,54

W_ERR: Hedef fonem: 372; Correct: 294; Incorrect: 73; Missing: 5; Extra: 23; İşaretli: 78; Ana metrik: tespit = %65,62

W_ERR grubunda 64 tasarlanmış hata konumunun 42’si işaretlenmiştir ($42/64 = \%65,62$). Precision-at-error, tüm işaretli hedef fonemlerin içinde tasarlanmış hata konumuna denk gelenlerin oranıdır ($42/78 = \%53,85$). Bu değer bilinçli olarak katıdır: konuşmacının aynı sözcükte hedeflenmemiş ama gerçek bir sapma üretmesi durumunda, sistemin işaretlediği bu

konum metrikte yanlış pozitif görünür. Bu nedenle precision-at-error değeri, canlı öğrenici performansından çok kontrollü isteme ne kadar hedefli tepki verildiğini gösteren bir alt sınır olarak yorumlanmalıdır.

Ortalama fonem skoru doğal doğru gruplarda yüksek kalmıştır: CTL için 0,9681, W_NAT için 0,9690. W_ERR grubunda ortalama 0,9156'ya düşmektedir. Bu fark, status etiketlerinden bağımsız olarak sürekli skorun da kasıtlı hata kümesini doğal doğru üretimlerden ayırdığını gösterir. Ancak skor tek başına pedagojik karar değildir; kullanıcıya sunulan satır düzeyi açıklama status, score_reason, quality, length ve gerekirse changed_by_analysis alanlarının birlikte okunmasını gerektirir.

Konuşmacı kırılımı, global sonucun tek bir konuşmacıdan kaynaklanmadığını ama küçük set etkisinin görünür kaldığını gösterir. K1'de doğal doğru yanlış-pozitif oranları K2'den yüksektir; buna karşılık W_ERR tespiti iki konuşmacıda da aynı banttadır. Bu kırılım tanısallık olarak yararlıdır, ancak iki konuşmacıyla sınırlı olduğu için demografik genelleme olarak okunmamalıdır.

K1: CTL işaretli yanlış-pozitif: %7,05; W_NAT işaretli yanlış-pozitif: %6,94; W_ERR tespit: %68,75 (22/32)

K2: CTL işaretli yanlış-pozitif: %3,52; W_NAT işaretli yanlış-pozitif: %4,14; W_ERR tespit: %62,50 (20/32)

Varsayılan MMS-1B yerine aynı protokolle XLS-R-300M kullanıldığında ana davranış değişmemiştir. XLS-R, CTL'de %5,07 (23/454), W_NAT'te %5,81 (87/1.498) yanlış-pozitif üretmiş; W_ERR tespiti yine %65,62 (42/64) kalmış, precision-at-error %56,00 (42/75) olmuştur. Bu sağlamlık kontrolü, güvenlik–tespit dengesinin tek bir backbone seçimine özgü olmadığını; aynı eğitim ve değerlendirme protokolünde iki modelin benzer feedback davranışı ürettiğini gösterir.

MMS-1B: CTL işaretli yanlış-pozitif: %5,29 (24/454); W_NAT işaretli yanlış-pozitif: %5,54 (83/1.498); W_ERR tespit: %65,62 (42/64); Hata-konumu kesinliği: %53,85 (42/78)

XLS-R-300M: CTL işaretli yanlış-pozitif: %5,07 (23/454); W_NAT işaretli yanlış-pozitif: %5,81 (87/1.498); W_ERR tespit: %65,62 (42/64); Hata-konumu kesinliği: %56,00 (42/75)

4.5. Kategori Kırılımı

Hedef hata yakalama davranışı fonem sınıfına göre belirgin biçimde değişir. Kasıtlı hata konumlarında ünlülerde yakalama oranı $26/30 = \%86,67$ iken ünsüzlerde $16/34 = \%47,06$ 'dır. Doğal doğru konuşmadaki işaretli olaylar ise yalnız ünlü/ünsüz kontrastlarından oluşmaz; 107 işaretli olayın 26'sı missing durumudur ve gözlenen bir alternatif foneme bağlanmadığı için ayrı tutulmalıdır.

Ünlü kontrastı: Doğal doğru işaret: 32/107; Yanlış-pozitif içindeki pay: %29,91; W_ERR hedef konum: 30/64; Yakalananlar içindeki pay: 26/42; Tespit: %86,67

Ünsüz kontrastı: Doğal doğru işaret: 49/107; Yanlış-pozitif içindeki pay: %45,79; W_ERR hedef konum: 34/64; Yakalananlar içindeki pay: 16/42; Tespit: %47,06


Missing: Doğal doğru işaret: 26/107; Yanlış-pozitif içindeki pay: %24,30; W_ERR hedef konum: 0/64; Yakalananlar içindeki pay: 0/42; Tespit: —

Bu kırılım sistemin en güçlü tespit sinyalinin ünlü kontrastlarında toplandığını gösterir. Türkçede ön/art, yuvarlaklık ve açık /e/ gibi ünlü farkları hem wav2vec posterior’unda hem atlas formant uzayında daha görünürdür. Ünsüzlerde ise özellikle kısa patlayıcılar, palatal/velar varyantlar ve allofonik üretimler zamanlama ve kayıt koşullarına daha duyarlı olduğundan sistem daha fazla kabul veya hedeflenmemiş işaret üretir. missing olaylarının doğal doğru yanlış-pozitifler içinde ayrı bir pay taşıması, frontier analizinde missing yumuşatmasının neden güçlü bir güvenlik etkisi ürettiğini açıklar.

4.6. Güvenlik–Tespit Dengesi

Varsayılan çalışma noktası, hedef-gözlem hizalamasındaki her sapmayı (incorrect veya missing) işaretler. Bu agresif politika tespiti yüksek tutar, ancak doğal-doğru konuşmada görece yüksek bir yanlış-pozitif oranı üretir. Mevcut iki konuşmacılı doğrulama setinde yanlış-pozitiflerin gerçek kasıtlı hatalardan ne fonetik mesafeyle (skor) ne de tanıyıcı güveniyle güvenilir biçimde ayıramadığı gözlenmiştir: doğal-doğru konuşmadaki yanlış işaretlerin büyük bölümü, tanıyıcının yüksek güvenle ürettiği ünsüz tanıma sapmalarıdır (örneğin /n/ → [ɲ], /s/ → [β], /pʰ/ → [b]); kasıtlı hatalar ise çoğunlukla ünlü kontrastlarında (ön/art, yuvarlaklık) yoğunlaşır. Bu yapı, bu validation kapsamında kararı güvenli biçimde yumuşatmak için elde kalan başlıca bilginin tek tek skor değil, kontrastın hangi sınıfta olduğu olduğunu gösterir.

Bu nedenle güvenlik–tespit dengesi, incorrect/missing kararlarını kontrast sınıfına ve fonetik mesafeye göre kademeli olarak yumuşatan politikalarla ölçülmüştür; sonuçlar Tablo 2’de özetlenmiş, Şekil 10’da görselleştirilmiştir. “Allofonik” politika aynı fonemin yüzey varyantı sayılan ikameleri (örneğin uzun ↔ kısa ünlü, /e/ ↔ /æ/) hata saymaz. “Yalnız ünlü” politika yalnız non-allofonik ünlü ikamelerini işaretler; “Ünlü + missing” satırında aynı ikameler korunur, fakat missing hedefler işaretlenmez. “Ünlü veya büyük ünsüz” politika ünlü ikamelerine ek olarak fonetik mesafe skoru 0,30’un altında kalan büyük ünsüz sapmalarını işaretler; son satır aynı kuralı missing yumuşatmasıyla uygular. Bu kademeler yanlış-pozitifi %5,29/%5,54’ten %0,22/%0,80’e kadar düşürebilir. Ancak bu güvenlik kazanımının bedeli, tespitin %65,62’den yaklaşık %30’a düşmesidir; çünkü tanıyıcının güvenilir olmadığı ünsüz kontrastlarında çekimser kalan politika, o kontrastlardaki gerçek kasıtlı hataları da kaçırır.



Şekil 10. İki anadili konuşmacılı dondurulmuş doğrulama setinde güvenlik–tespit dengesi. Her nokta aynı 150 kaydın farklı bir sonradan yorumlama politikasıyla okunmasını gösterir; yanlış-pozitif düşüren politikalar tespiti de düşürmektedir.

Tablo 2. Güvenlik–tespit dengesi: aynı 150 kaydın farklı sonradan yorumlama politikalarıyla okunması.

Varsayılan: CTL yanlış-pozitif: %5,29 (24/454); W_NAT yanlış-pozitif: %5,54 (83/1498); Tespit: %65,62 (42/64); Hata-konumu kesinliği: %53,85 (42/78)

Allofonik: CTL yanlış-pozitif: %4,41 (20/454); W_NAT yanlış-pozitif: %4,67 (70/1498); Tespit: %51,56 (33/64); Hata-konumu kesinliği: %50,77 (33/65)

Yalnız ünlü: CTL yanlış-pozitif: %1,54 (7/454); W_NAT yanlış-pozitif: %2,14 (32/1498); Tespit: %29,69 (19/64); Hata-konumu kesinliği: %59,38 (19/32)

Ünlü + missing: CTL yanlış-pozitif: %0,22 (1/454); W_NAT yanlış-pozitif: %0,80 (12/1498); Tespit: %29,69 (19/64); Hata-konumu kesinliği: %70,37 (19/27)

Ünlü veya büyük ünsüz: CTL yanlış-pozitif: %2,20 (10/454); W_NAT yanlış-pozitif: %2,54 (38/1498); Tespit: %32,81 (21/64); Hata-konumu kesinliği: %50,00 (21/42)

Ünlü veya büyük ünsüz + missing: CTL yanlış-pozitif: %0,88 (4/454); W_NAT yanlış-pozitif: %1,20 (18/1498); Tespit: %32,81 (21/64); Hata-konumu kesinliği: %56,76 (21/37)

Bu tablo tezin temel sonuçlarından biridir: bu iki konuşmacılı doğrulama setinde ve mevcut serbest-çözümleme/status politikası ailesinde daha güvenli geri bildirim, basit bir eşik ya da güven kapısıyla değil, tespitten ödün vererek elde edilebilmektedir. Denge, varsayılan çalışma noktasının neden tespit lehine bırakıldığını ve düşük yanlış-pozitif gerektiren bir dağıtımın hangi tespit maliyetini kabul etmek zorunda kalacağını açıkça gösterir. Bu bulgunun pedagojik sonuçları Tartışma bölümünde ele alınır.

4.7. Status Dağılımının Yorumu

incorrect ve missing durumları doğrulama metriklerinde birlikte işaretli sayılmıştır, ancak pedagojik anlamları farklıdır. incorrect, hedef fonemin başka bir analiz fonemine hizalandığını; missing, hedef fonemin gözlem dizisinde karşılık bulamadığını belirtir. CTL grubunda 18 incorrect ve 6 missing, W_NAT grubunda 63 incorrect ve 20 missing görülmüştür. W_ERR grubunda ise 73 incorrect ve 5 missing vardır; bu dağılım kasıtlı hata setinde hataların çoğunun eksilme değil hedef-dışı fonem üretimi olarak yakalandığını gösterir.

extra durumu ayrı değerlendirilmiştir. CTL’de 1, W_NAT’te 10 ve W_ERR’de 23 extra satırı vardır. Bu satırlar hedef fonem başına yanlış-pozitif oranını artırmaz; fakat sözcük puanında extra_penalty ile etkili olur. Böylece sistem hedef konumlu hatalar ile fazladan duyulan fonemleri aynı hata türü gibi göstermeden puanlayabilir.

4.8. Sonuçların Özeti

G2P sonuçları hedef dizinin güvenilir olduğunu, wav2vec sonuçları fonem tanımanın temel sınıflarda güçlü olduğunu, atlas sonuçları ise akustik referans modelinin hangi fonemlerde güvenilir sinyal taşıdığını göstermektedir. İki anadili konuşmacılı değerlendirme bu bileşenlerin çalışma zamanında birlikte kullanılabildiğini doğrulamıştır. Sistem doğal konuşmada hedef fonemlerin yaklaşık %94–95’ini correct bırakırken kasıtlı hata konumlarının yaklaşık üçte ikisini işaretlemektedir. Bu sonuç, değerlendirme sisteminin üretimsel hedefini destekler: kullanıcıya yalnızca tanıyıcı çıktısı değil, fonem düzeyinde status, sürekli skor, ünlülerde kalite ve süre kanıtına dayalı temkinli geri bildirim vermek. Bulgular bölümünün ana metrikleri, Tartışma bölümünde “tanıma başarısı $\neq$ geri bildirim güvenliği” tezi çerçevesinde sınırlamaları ve sistemin pedagojik konumu bakımından yeniden değerlendirilecektir.

5. Tartışma

5.1. Bulguların Genel Yorumu

Bu çalışmanın bulguları, Türkçe telaffuz değerlendirmesinde genel fonem tanıma başarısı ile kullanıcıya verilecek geri bildirimin güvenliği arasında doğrudan eşitlik kurulamayacağını göstermektedir. G2P motoru hedef fonem dizisini yüksek doğrulukla üretmekte (Blind-75 PER = 0,015), wav2vec tabanlı CTC modeli temel fonemleri düşük hata oranıyla tanımakta (Full IPA PER yaklaşık %4,1) ve değerlendirme motoru bu sinyalleri fonem düzeyinde status/score satırlarına dönüştürmektedir. Ancak değerlendirme sonuçları, güçlü tanıma sinyalinin tek başına pedagojik geri bildirim için yeterli olmadığını da göstermektedir.

İki anadili konuşmacılı stüdyo setinde doğal doğru gruplardaki işaretli yanlış-pozitif oranı CTL için %5,29, W_NAT için %5,54'tür. Buna karşılık W_ERR grubunda kasıtlı hata konumlarının %65,62'si incorrect veya missing olarak yakalanmıştır. Precision-at-error %53,85'tir; bu metrik yalnız tasarlanmış hata konumunu doğru kabul ettiği için, konuşmacının aynı sözcükte ürettiği hedeflenmemiş gerçek sapmaları da paydada cezalandırır. Bu nedenle sonuçlar “her hatayı yakalayan hakem” iddiası değil, kontrollü hata konumlarına duyarlı ve status/score kanıtını açıkça raporlayan bir değerlendirme hattı olarak okunmalıdır. Tartışma açısından kritik nokta, aynı sistemin hem doğru üretimleri koruma hem de tasarlanmış sapmaları yakalama hedefini birlikte taşımasıdır; metriklerin her biri bu iki hedefin farklı tarafını görünür kılar.

5.2. Status Tabanlı Tasarımın Anlamı

Yeni çalışma zamanı sözleşmesi, tek bir karar etiketi yerine hedef-gözlem hizalamasını ve sürekli fonetik mesafe skorunu merkeze alır. correct hedef fonemin desteklendiğini, incorrect hedefin başka bir analiz fonemine hizalandığını, missing hedef fonemin gözlenmediğini, extra ise hedef satırı olmayan ek gözlemi belirtir. Bu ayırım pedagojik olarak önemlidir: bir eksilme, bir hedef-dışı fonem ve fazladan duyulan fonem aynı kullanıcı mesajını gerektirmez.

Sürekli score alanı, bu status sınıflarını derecelendirir. Tam eşleşme tam puan alırken, ünlülerde yükseklik/artlık/yuvarlaklık/uzunluk; ünsüzlerde yer/biçim/ötümlülük/aspirasyon farkları dereceli cezalara dönüşür. Böylece bir /i/ yerine /u/ üretimi ile hedef dışı sınıflar arası büyük bir sapma aynı şiddette değerlendirilmez. quality ve length alanlarının ayrı tutulması da bu tasarımı tamamlar: ünlülerde akustik tipiklik ve süre kanıtı, hedef-gözlem kimliğini doğrudan geçersiz kılmadan açıklayıcı sinyal sağlar.

5.3. Güvenlik ve Tespit Dengesi

Doğal doğru konuşmada %5 civarındaki işaretli yanlış-pozitif oranı, sistemin hâlâ üretim dağıtımına hazır bir kesin öğretmen otoritesi olmadığını gösterir. Bu oran önceki ikili etiketleme hedeflerine göre daha yüksek görünse de yeni sözleşmede incorrect ve missing birlikte sayılır; yani metrik artık yalnız “sert hata etiketi” değil, hedef fonemin kabul edilmediği tüm durumları ölçmektedir. Bu daha dürüst ama daha katı bir güvenlik okumasıdır.

Bu denge, varsayılan çalışma noktasının yegâne seçenek olmadığını da gösterir. Bulgular bölümündeki Tablo 2, incorrect/missing kararlarının kontrast sınıfına ve fonetik mesafeye göre kademeli yumuşatılmasıyla elde edilen güvenlik–tespit eğrisini özetler. Kritik bulgu, mevcut iki konuşmacılı doğrulama seti, serbest çözümleme + status politikası ve kullanılan skor/güven sinyalleri altında yanlış-pozitiflerin gerçek sapmalardan ne fonetik mesafeyle ne de tanıyıcı güveniyle güvenilir biçimde ayrılamamasıdır: doğal-doğru konuşmadaki yanlış işaretlerin büyük bölümü, tanıyıcının yüksek güvenle ürettiği ünsüz tanıma sapmalarıdır (örneğin /n/ → [ɲ], /s/ → [ʃ]) ve kasıtlı hatalarla aynı skor/güven bandında yer alır. Bu nedenle bu doğrulama kapsamındaki basit bir eşik ya da güven kapısı, yanlış-pozitifi tespitten bağımsız olarak düşüremez. Yalnız tanıyıcının görece güvenilir olduğu ünlü kontrastlarına güvenen temkinli bir politika, işaretli yanlış-pozitifi %1’in altına indirebilir; ancak aynı politika tespiti %65,62’den yaklaşık %30’a düşürür. Bu sonuç, “tanıma başarısı ≠ geri bildirim güvenliği” tezinin doğrudan nicel kanıtıdır: aynı kayıt kümesinde güvenlik ile tespit birbirine takas edilir ve mevcut sinyal/politika ailesinde ikisi birden serbestçe iyileştirilemez. Dolayısıyla düşük yanlış-pozitif gerektiren bir üretim dağıtımı, ya bu tespit maliyetini bilinçli olarak kabul etmeli ya da geri bildirimini yalnız tanıyıcının güvenilir olduğu kontrastlarla sınırlamalıdır.

W_ERR tarafında %65,62 detection, sistemin kontrollü hataların önemli bölümünü yakalayabildiğini gösterir. Ünlülerde detection %86,67’ye çıkarken ünsüzlerde %47,06’da kalır. Bu fark Türkçede de belirginleşen genel fonetik/akustik durumla uyumludur: ön/art ve yuvarlaklık gibi ünlü farkları formant uzayında daha görünürken, kısa ünsüzler ve allofonik varyantlar zamanlama, burst ve kayıt koşullarına daha duyarlıdır. Bu nedenle sonraki teknik kazanım için öncelikli hipotez, ünsüzlere özel VOT, release-burst ve geçiş özelliklerinin daha güvenilir modellenmesidir.

5.4. Tanıma Başarısı Geri Bildirim Güvenliği Değildir

wav2vec modellerinin yaklaşık %4,1 Full IPA PER bandına ulaşması, hedefe koşullu değerlendirme için güçlü bir başlangıçtır; ancak bu değer doğrudan kullanıcı geri bildirim güvenliğine çevrilemez. Fonem tanıma hataları doğal konuşmada masum varyasyonu da

hedef-dışı gözlem gibi gösterebilir. Ters yönde, tanıyıcı kasıtlı hatayı hedef fonem olarak çözümlediğinde status motorunun yakalayabileceği gözlenebilir bir fark kalmaz.

Bu nedenle sistemin ana katkısı, tanıyıcı çıktısını tek başına karar yerine koymamasıdır. Çalışma zamanı target, wav2vec, analysis ve result bloklarını ayrı tutar. Ham tanıyıcı çıktısı, akustik analiz adayları ve nihai hizalama farklı bloklarda görülebildiği için, kullanıcı arayüzü ve araştırmacı raporları “model ne duydu?”, “analiz neyi düzeltti?” ve “sonuç hangi status/score ile çıktı?” sorularını ayırabilir. Açıklanabilirlik literatüründe vurgulanan model davranışını denetlenebilir hale getirme ilkesi (Doshi-Velez ve Kim 2017; Lipton 2018) burada pratik bir çıktı sözleşmesine dönüşmektedir.

5.5. Değerlendirme Setinin Sınırları

Stüdyo seti kontrollü ve tanısal bir settir; geniş popülasyon temsili iddiası taşımaz. İki anadili konuşmacı, regresyon ve sistem davranışı okuması için yeterli bir başlangıç sağlar; fakat yaş, cinsiyet, aksan, mikrofon, oda akustiği ve öğrenici ana dili çeşitliliğini temsil etmez. Kasıtlı yanlış üretimlerde konuşmacının her zaman planlanan yanlış fonemi tam olarak üretmesi de garanti değildir. Bu nedenle W_ERR metrikleri gerçek L2 öğrenici davranışına doğrudan genellenmemelidir.

Gerçek öğrenici doğrulaması için çoklu puanlayıcı protokolü gereklidir. En az iki Türkçe öğretmeni puanlayıcı ve bir fonetikçiyle oluşturulacak fonem düzeyli etiketler, sistemin incorrect/missing kararlarının insan puanlarıyla uyumunu Cohen’s κ , F1-score ve hata türü bazlı precision/recall ile ölçmeyi mümkün kılar. Böyle bir veri toplama süreci hedef ana dil gruplarını, minimum konuşmacı/istem örneklemini, puanlayıcı eğitimini, uyumsuzluk çözüm protokolünü ve açık onam/veri saklama koşullarını baştan tanımlamalıdır. L2-ARCTIC (Zhao vd. 2018) ve speechocean762 (Zhang vd. 2021) gibi çok-puanlayıcılı corpus’lar, yöntemsel karşılaştırma için yararlı çerçeveler sunar; ancak Türkçe için yine dil-özel veri gerekir.

Bu sınırlılıklar dört geçerlilik boyutunda okunmalıdır. İç geçerlilik açısından dondurulmuş kayıt seti ve deterministik değerlendirme hattı aynı girdinin aynı çıktıyı vermesini sağlar; ancak konuşmacının kasıtlı hatayı tam planlandığı gibi üretip üretmediği ayrı bir belirsizliktir. Dış geçerlilik açısından iki anadili konuşmacı ve stüdyo koşulu, gerçek öğrenici popülasyonunu temsil etmez. Yapı geçerliliği açısından incorrect/missing status’u, öğretmen yargısı ya da anlaşılabilirlik puanı değil, hedef-gözlem hizalamasından türeyen teknik bir göstergedir. Ekolojik geçerlilik açısından push-to-talk prototip, canlı kullanım akışını gösterir; fakat motivasyon, öğrenme kazanımı ve uzun dönemli davranış değişimi ölçmez.

5.6. Literatürle İlişki

Bu tez, telaffuz değerlendirmesini yalnızca konuşma tanıma performansı olarak ele almayan çalışmalarla aynı yöndedir. Klasik GOP tabanlı puanlama (Witt ve Young 2000; Neumeyer vd. 2000; Hu vd. 2015), DNN tabanlı yanlış telaffuz tespiti (Harrison vd. 2009; Li vd. 2017; Leung vd. 2019; Wu vd. 2021) ve çağdaş çok görevli telaffuz puanlama yaklaşımları (Gong vd. 2022; Chen vd. 2024; Shahin vd. 2025; Ye vd. 2022; Lin ve Wang 2021) tek bir ham tanıma çıktısından daha zengin kanıt kullanımının gerekliliğini göstermiştir. Bu çalışmanın farkı, Türkçeye özgü G2P hedef üretimini, fonem CTC modelini, atlas-tabanlı kalite sinyali ve status-tabanlı fonetik mesafe skorunu tek bir çalışma zamanı sözleşmesinde birleştirmesidir.

Literatürle ilişki üç düzeyde kurulabilir. GOP ve MDD çizgisi, beklenen fonemin akustik destek düzeyini ve hedef-dışı üretimi ölçme fikrini sağlar; bu tez bu çizgiyi Türkçe hedef dizisine koşullu, serbest CTC çözümleme + edit hizalamasıyla çalışan bir sözleşmeye taşır. Çok görevli APA/CAPT çalışmaları, sözcük ve cümle düzeyinde çoklu puanlamanın önemini gösterir; bu tez ise kapsamını fonem düzeyinde status, skor, ünlü kalite ve süre kanıtıyla sınırlı tutar. Türkçe ASR/G2P ve Türkçe öğretimi/diksiyon literatürü ise yerel dilsel bağlamı sağlar; bu tez doğrudan öğrenme kazanımı çalışması değil, bu bağlamda kullanılabilecek güvenlik odaklı bir teknik prototiptir.

5.7. Pedagojik ve Etik Sınırlar

Sistem kullanıcıya kesin öğretmen otoritesi gibi sunulmamalıdır. Hata yakalaması anlamlı bir sinyaldir; hata yakalamaması ise telaffuzun kesin doğru olduğu anlamına gelmez. incorrect, missing ve extra durumları kullanıcıya aynı dille sunulmamalı; her biri hedef fonem, duyulan fonem, skor nedeni ve mümkünse kalite/uzunluk kanıtıyla açıklanmalıdır. Örneğin düşük güvenli bir ünsüz ikamesi “yanlış söylediniz” yerine “bu konumda hedef fonem için kanıt zayıf; tekrar deneyin veya öğretmen kontrolü gerekir” biçiminde sunulmalıdır. Klinik konuşma bozuklukları, çocuk konuşması ve gürültülü mobil kayıtlar mevcut doğrulama kapsamının dışındadır; bu popülasyonlarda ayrı atlas, ayrı kalibrasyon ve ayrı etik uyarılar gerekir.

Veri gizliliği de üretim dağıtımı için kritik bir konudur. Kayıt arşivleme yalnızca açık onamla yapılmalı, onam yoksa ses saklama kapatılmalıdır. Bu tezdeki sistem araştırma ve prototip bağlamında değerlendirilmiştir; canlı ürün kullanımında saklama politikası, silme hakkı ve kullanıcıya gösterilen açıklamalar ayrıca denetlenmelidir.

5.8. Gelecek Çalışma

Bir sonraki adım gerçek Türkçe öğrencilerinden insan etiketli kayıt toplamaktır. Bu veri, kasıtlı yanlış üretimden farklı olarak doğal hata dağılımını ve hata türü çeşitliliğini gösterecektir.

İkinci yön, konuşmacıya özgü kısa kalibrasyon oturumudur: birkaç kanonik kayıtlarla konuşmacının F1/F2 merkezleri ve süre profili ölçülerek atlas log-yoğunluk dağılımı konuşmacı bazında merkezlenebilir.

Üçüncü yön, ünsüzler için VOT, spektral momentler ve release-burst özelliklerinin eklenmesidir. Bu özellikler özellikle ünsüz kontrastlarında tespiti artırma potansiyeli taşır; ancak kullanıcıya dönük karara katılmadan önce yanlış-pozitif etkileri ayrı ölçülmelidir.

Dördüncü yön, status satırlarını kullanıcıya dönük açıklama şablonlarına bağlamaktır. Bu çalışma hattı, teknik status etiketlerini öğretmen dili, tekrar deneme önerisi ve belirsizlik bildirimiyle eşleştiren ayrı bir kullanıcı deneyimi doğrulaması gerektirir.

Prozodik değerlendirme de ayrı bir katman olarak ele alınmalıdır. Mevcut sistem yalnızca fonem-içi süre kanalını yumuşak biçimde kullanır; cümle/sözcük seviyesi vurgu, tonlama ve akıcılık ayrı bir modelleme ve doğrulama protokolü gerektirir (Erdem Nas ve Akbulut 2021).

5.9. Tartışmanın Özeti

Bulgular, Türkçe için otomatik telaffuz değerlendirmesinin uygulanabilir olduğunu, fakat güvenli geri bildirim için hedef üretimi, akustik tanıma, atlas referansı ve status-tabanlı skorlamanın birlikte ele alınması gerektiğini göstermektedir. Yeni mimari doğal konuşmada hedef fonemlerin büyük bölümünü kabul eder, kasıtlı hata konumlarının yaklaşık üçte ikisini yakalar ve her fonem için gerekçeli bir status/score satırı üretir. Bu mimari, gelecekteki gerçek öğrenci doğrulamaları, konuşmacı normalizasyonu ve prozodik genişlemeler için sağlam bir başlangıç noktasıdır.

6. Sonuç ve Öneriler

Bu tezde, Türkçe diksiyon ve telaffuz değerlendirmesi için yapay zeka tabanlı, açıklanabilir ve pedagojik açıdan temkinli geri bildirim üretmeyi hedefleyen bir telaffuz değerlendirme sistemi geliştirilmiştir. Çalışmanın amacı konuşmayı yalnızca metne ya da fonem dizisine dönüştürmek değil; hedef fonem dizisini üreten, konuşma kaydını bu hedefle hizalayan ve kullanıcıya durum, sürekli skor ile ünlü kalite/süre kanıtına dayalı geri bildirim veren bütünleşik bir sistem kurmaktır. Sistem dört ana bileşenden oluşur ve hepsi aynı 49 birimli IPA tabanlı hedef etiket envanterini paylaşır; bu paylaşılan envanter, G2P çıktısının doğrudan CTC etiketine, çalışma zamanı hedef dizisine ve atlas referansına aktarılmasını mümkün kılar.

İlk çıktı, Türkçenin fonetik özelliklerini dikkate alan G2P motorudur. Motor, 49 birimli hedef etiket envanteri ve birincil vurgu işaretiyle hedef telaffuz üretmekte; yumuşak g (altı bağlama bağlı yüzey gerçekleşmesi), açık /e/, k/g palatalizasyonu, uzun ünlü (alıntı circumflex ve fonolojik uzatma), lateral allofonisi, nazal benzeşme, sözcük-sonu /t/ ötümsüzleşmesi ve Sezer cretic tabanlı vurgu gibi olayları 15 aşamalı dönüşüm hattıyla ele almaktadır. Blind-75 doğrulama setinde PER = 0,015 ve %98,52 sembol doğruluğu, MFA Türkçe sözlüğünde 41.373 sözcükte PER = 0,032, Wiktionary’de 14.015 sözcükte PER = 0,118 elde edilmesi, bu bileşenin değerlendirme sistemi için sağlam ve doğrulanmış bir hedef tabanı sağladığını göstermiştir.

İkinci çıktı, Türkçe fonem tanıma için wav2vec tabanlı CTC modellerinin eğitilmesidir. Aynı 54 birimli dağarcık ve aynı eğitim/dev/test bölmesi (275,48 + 15,97 + 18,65 saat) ile XLS-R-300M test kümesinde %4,05 Full IPA PER ve %3,49 Segmental PER üretmiş; MMS-1B aynı protokolde %4,13 Full IPA PER ve %3,62 Segmental PER elde etmiştir. MMS-1B bu tezde sonuç-kayıt hattının varsayılan modeli olarak kullanılmış, XLS-R-300M ise aynı protokolle sağlamlık kontrolü olarak yan yana tutulmuştur; bu seçim üstün PER iddiası değil, uçtan uca doğrulama hattının sabitlenmiş varsayılanıdır. Bu sonuçlar çok dilli öz denetimli modellerin Türkçe fonem tanıma için kullanılabilir olduğunu göstermektedir (Babu vd. 2022; Pratap vd. 2024).

Üçüncü çıktı, fonem atlasından türetilen akustik referans modelidir. Atlas, 463.003 segment, 544,72 saat ses ve 22,4 milyon fonem penceresi üzerinden fonem-başına formant (F1/F2/F3 + ünlüler için F2 hareketi), süre ve kapsam istatistikleri sağlamış; çevrimdışı bir adımla bu istatistiklerden fonem-başına Gaussian karışım modelleri eğitilmiştir. 47 fonemde üç bileşenli GMM, /u:/ ve /y:/ için ise düşük örnekli tek bileşenli fallback modeli tutulmuştur. Çalışma zamanında ölçülen özellik vektörünün GMM log-yoğunluğu, fonem-özgü quantile tablosuyla [0, 1] aralığına eşlenerek özellikle ünlülerde quality kanıtı olarak raporlanır. Bu yapı ünlü açıklığı ve ön-art ayrımı gibi Türkçeye özgü ayrımlarda tanıyıcı çıktısından farklı bir kanıt

yüzeyi sağlamakta; lateral allofoni ve ünsüz özellikleri ise mevcut sürümde kullanıcıya dönük bağımsız kalite hükmünden çok tanısıl analiz kapsamı olarak tutulmaktadır. Uzun-kısa ünlü ayırımında belirleyici sinyal kalite puanından çok süre kanalında izlenmektedir.

Dördüncü çıktı, uçtan uca prototip olarak çalıştırılan değerlendirme motorudur. Motor, G2P hedef dizisini wav2vec serbest çözümlemesiyle düzenleme-mesafesi hizalaması üzerinden eşleştirir ve hedef satırları için correct, incorrect veya missing, hedefte bulunmayan fazladan gözlemler için extra durumu ile sürekli bir fonetik mesafe skoru (score) üretir; ünlülerde akustik tipiklik (quality) ve süre (length) bu kimliği geçersiz kılmayan ayrı, açıklayıcı kanallar olarak raporlanır. İki anadili konuşmacılı 150 kayıtlık doğrulamada CTL grubunda işaretli yanlış-pozitif oranı %5,29, W_NAT grubunda %5,54; W_ERR grubunda kasıtlı hata tespiti %65,62 (42/64) ve precision-at-error %53,85 (42/78) olarak ölçülmüştür. Bu sonuç, sistemin kontrollü kasıtlı hata konumlarının yaklaşık üçte ikisini yakalayabildiğini, ancak bunu doğal-doğru konuşmada görece yüksek bir yanlış-pozitif oranı pahasına yaptığını gösterir; W_ERR doğal L2 hata dağılımı veya öğretmen puanlı öğrenci doğrulaması yerine geçmez.

Tezin ana sonucu, Türkçe telaffuz değerlendirmesinde güvenlik odaklı geri bildirim ilkesinin teknik mimarinin merkezine yerleştirilmesi gerektiğidir. Sistem her hizalama satırı için ayrı bir durum, sürekli skor, ünlülerde kalite ve süre kanıtı üreterek belirsiz durumları tek bir “doğru/yanlış” damgasına indirgemekten kaçınır; ham tanıma, akustik analiz ve nihai hizalamayı ayrı bloklar hâlinde raporlayarak kararı denetlenebilir kılar.

Bununla birlikte tezin kritik bulgusu, tanıma başarısı ($PER \approx \%4,1$) ile geri bildirim güvenliği (doğal konuşmada işaretli yanlış-pozitif $\approx \%5$) arasında doğrudan bir köprü kurulamayacağıdır. Mevcut iki konuşmacılı doğrulama seti, serbest çözümleme + status politikası ve kullanılan skor/güven sinyalleri altında yanlış-pozitifler ile gerçek sapmalar ne fonetik mesafeyle ne de tanıyıcı güveniyle güvenilir biçimde ayrılmadığından, güvenli geri bildirim bir denge (frontier) sorununa dönüşür: tanıyıcının güvenilir olmadığı (çoğunlukla ünsüz) kontrastlarda çekimser kalan bir politika yanlış-pozitifleri %1’in altına indirebilir, fakat tespiti yaklaşık %30’a düşürür. Tanıma başarısı (PER) ve geri bildirim güvenliği farklı metriklerle ölçülen farklı olgulardır; tez bu iki düzeyi açıkça ayırmış ve aralarındaki dengeyi Tartışma bölümünde ayrıntılı raporlamıştır.

Çalışmanın sınırlılıkları açıktır. Sistem klinik konuşma bozukluğu tanısı veya terapi amacı taşımaz. Gerçek Türkçe öğrencileriyle geniş popülasyon doğrulaması yapılmamıştır; öğrenme kazanımı, öğretmen puanıyla uyum, kullanıcı motivasyonu ve anlaşılabilirlik etkisi ölçülmemiştir. Değerlendirme seti kontrollü ve görece küçüktür; bazı fonetik kategoriler az

sayıda istemle temsil edilmiştir. Vurgu bu tezde G2P hedef envanterinin sembolik bir ögesi olarak tutulmuş, bağımsız bir kullanıcı feedback kanalı olarak doğrulanmamıştır. Uzun ünlülerde süre kanalı açıklayıcı sinyal sağlar; ancak tonlama, ritim, akıcılık ve sözcük/cümle düzeyi vurgu için geniş bir prozodi değerlendirmesi yapılmamıştır. Konuşmacı kırılımı, aynı global politikanın iki konuşmacıda farklı incorrect/belirsizlik dengeleri üretebildiğini göstermiştir; mikrofon, oda akustiği ve mobil/gürültülü kayıt çeşitliliği ayrıca doğrulanmamıştır.

6.1. Öneriler

Gelecek çalışma için ilk öneri, farklı ana dillere sahip Türkçe öğrencilerinden çoklu puanlayıcı protokolüyle insan puanlı bir doğrulama seti oluşturmaktır. Hedef ana dil grupları, minimum konuşmacı/istem örnekleme, puanlayıcı eğitim protokolü, uyumsuzluk çözümü ve etik/onam adımları veri toplama başlamadan tanımlanmalıdır. En az iki Türkçe öğretmeni ve bir fonetikçiyle hazırlanacak etiketler, sistemin status kararlarının öğretmen yargısıyla uyumunu ve gerçek öğrenci hata dağılımındaki davranışını ölçmeyi mümkün kılar.

İkinci öneri, teknik kalibrasyonun konuşmacı ve kontrast düzeyinde genişletilmesidir. Konuşmacıya özgü kısa kalibrasyon oturumları atlas tabanlı kalite kanıtının yanlış-pozitif oranını düşürebilir. Düşük kapsamlı ünsüzler için VOT, spektral momentler ve release-burst özellikleri ancak yanlış-pozitif etkileri ayrı ölçüldükten sonra kullanıcıya dönük karara katılmalıdır.

Üçüncü öneri, kullanıcıya gösterilen açıklama katmanının ayrı bir araştırma konusu olarak ele alınmasıdır. Sistem durum satırları, “yanlış” gibi kesin etiketler yerine hedef fonem, duyulan aday, güven düzeyi, tekrar deneme ve öğretmen kontrolü gibi güvenli geri bildirim şablonlarına bağlanmalıdır. Bu katman kullanıcı motivasyonu ve anlaşılabilirlik çalışmalarıyla birlikte doğrulanmalıdır.

Dördüncü öneri, üretim dağıtımı için veri gizliliği ve onam politikasının sertleştirilmesidir. Ses saklama, silme hakkı, anonimleştirme ve araştırma dışı kullanım sınırları açıklanmadan canlı ürün iddiasına geçilmemelidir.

Beşinci öneri ise prozodik değerlendirmeyi fonem süresinden sözcük/cümle düzeyindeki vurgu, tonlama ve akıcılığa genişletmektir; bu genişleme yeni veri, yeni metrik ve ayrı doğrulama protokolü gerektirir.

Sonuç olarak bu tez, Türkçe için otomatik telaffuz değerlendirmesinin uygulanabilir olduğunu, ancak bunun yalnızca konuşma tanıma problemi olarak ele alınamayacağını göstermiştir. Hedef telaffuz üretimi, fonem tanıma, atlas referansı ve status-tabanlı belirsizlik

yönetimi birlikte kullanıldığında daha güvenli ve denetlenebilir bir geri bildirim prototipi elde edilmektedir. Tezin nicelendirdiği güvenlik–tespit dengesi ise bu sistemin temel sınırını ve gelecekteki iyileştirme eksenlerini açıkça ortaya koymaktadır. Bu bütünlük hat, Türkçe telaffuz değerlendirme için geliştirilebilir, açık ve pedagojik açıdan temkinli bir araştırma omurgası sunmaktadır.

Kaynaklar

Akdoğan, Hülya. 2024. “Türkçenin Ana Dili Konuşurlar ile Türkçeyi Yabancı Dil Olarak Öğrenenlerin Sesli Okuma ve Konuşmada Diksiyon Öğelerini Kullanım Durumları”. Y{\“u}ksek Lisans Tezi, İstanbul Aydın Üniversitesi.

Altınok, Duygu. 2016. *Towards Turkish ASR: Anatomy of a Rule-Based Turkish G2P*. <https://doi.org/10.48550/arXiv.1601.03783>.

Amrate, Moustafa, ve Pi-hua Tsai. 2024. “Computer-Assisted Pronunciation Training: A Systematic Review”. *ReCALL* 37 (1). <https://doi.org/10.1017/S0958344024000181>.

Ardila, Rosana, Megan Branson, Kelly Davis, vd. 2020. “Common Voice: A Massively-Multilingual Speech Corpus”. *Proceedings of the Twelfth Language Resources and Evaluation Conference (LREC 2020)* (Marseille, France), 4218-22. <https://aclanthology.org/2020.lrec-1.520>.

Artuner, Harun. 1994. “Bir Türkçe Fonem Kümeleme Sistemi Tasarımı ve Gerçekleştirimi”. Doktora Tezi, Hacettepe Üniversitesi.

Babu, Arun, Changhan Wang, Andros Tjandra, vd. 2022. “XLS-R: Self-Supervised Cross-Lingual Speech Representation Learning at Scale”. *Interspeech 2022*, 2278-82. <https://doi.org/10.21437/Interspeech.2022-143>.

Baevski, Alexei, Henry Zhou, Abdelrahman Mohamed, ve Michael Auli. 2020. “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations”. *Advances in Neural Information Processing Systems* 33: 12449-60.

Bisani, Maximilian, ve Hermann Ney. 2008. “Joint-Sequence Models for Grapheme-to-Phoneme Conversion”. *Speech Communication* 50 (9): 755-65. <https://doi.org/10.1016/j.specom.2008.03.003>.

Boersma, Paul, ve David Weenink. 2026. *Praat: Doing Phonetics by Computer*. Computer program. <https://www.praat.org/>.

Chen, Yu-Wen, Zhou Yu, ve Julia Hirschberg. 2024. “MultiPA: A Multi-task Speech Pronunciation Assessment Model for Open Response Scenarios”. *Interspeech 2024*, 297-301. <https://doi.org/10.21437/Interspeech.2024-123>.

Chhabra, Priyanka, Shailja Chhillar, Riya Tanwar, Muskan Verma, ve Gaurav Indra. 2024. "Mispronunciation Detection Using Feature Learning". *Proceedings of the Third International Conference on Computing and Communication Networks*, Lecture Notes on Data Engineering ve Communications Technologies.

Çöltekin, Çağrı, A. Seza Doğruöz, ve Özlem Çetinoğlu. 2023. "Resources for Turkish Natural Language Processing: A Critical Survey". *Language Resources and Evaluation* 57: 449-88. <https://doi.org/10.1007/s10579-022-09605-4>.

Demircan, Ömer. 1996. *Türkçenin Sesezimi*. Der Yayınları.

Doshi-Velez, Finale, ve Been Kim. 2017. *Towards A Rigorous Science of Interpretable Machine Learning*. <https://doi.org/10.48550/arXiv.1702.08608>.

El Kheir, Yassine, Ahmed Ali, ve Shammur Absar Chowdhury. 2023. "Automatic Pronunciation Assessment – A Review". *Findings of the Association for Computational Linguistics: EMNLP 2023* (Singapore), 8304-24. <https://doi.org/10.18653/v1/2023.findings-emnlp.557>.

Erdem Nas, Gönül, ve Büşra Akbulut. 2021. "Yabancılar Türkçe öğretimine bürün bilimsel bir yaklaşım - Boşnak konuşurların Türkçe vurgu üretimleri". *Türk Dili Araştırmaları Yıllığı - Belleten* 69 (2): 315-42.

Ergenç, İclâl. 1995. *Konuşma Dili ve Türkçenin Söyleyiş Sözlüğü: Bir Deneme*. Simurg.

Gong, Yuan, Ziyi Chen, Iek-Heng Chu, Peng Chang, ve James Glass. 2022. "Transformer-Based Multi-Aspect Multi-Granularity Non-Native English Speaker Pronunciation Assessment". *ICASSP 2022 – 2022 IEEE International Conference on Acoustics, Speech and Signal Processing* (Singapore), 7262-66. <https://doi.org/10.1109/ICASSP43922.2022.9746743>.

Göksel, Aslı, ve Celia Kerslake. 2005. *Turkish: A Comprehensive Grammar*. Routledge.

Graves, Alex, Santiago Fernández, Faustino Gomez, ve Jürgen Schmidhuber. 2006. "Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks". *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, 369-76.

Guo, Chuan, Geoff Pleiss, Yu Sun, ve Kilian Q. Weinberger. 2017. "On Calibration of Modern Neural Networks". *Proceedings of the 34th International Conference on Machine Learning*, Proceedings of Machine Learning Research, c. 70: 1321-30. <https://proceedings.mlr.press/v70/guo17a.html>.

Gülen, Gizem. 2018. "Yabancı Dil Olarak Türkçe Öğretiminde Diksiyon". Y{\u}ksek Lisans Tezi, İstanbul Üniversitesi.

Harrison, Alissa M., Wai-Kit Lo, Xiao-Jun Qian, ve Helen Meng. 2009. "Implementation of an Extended Recognition Network for Mispronunciation Detection and Diagnosis in Computer-Assisted Pronunciation Training". *Proceedings of SLATE 2009*, 45-48. <https://doi.org/10.21437/SLATE.2009-12>.

Hsu, Wei-Ning, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, ve Abdelrahman Mohamed. 2021. "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units". *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 29: 3451-60.

<https://doi.org/10.1109/TASLP.2021.3122291>.

Hu, Wei, Yao Qian, Frank K. Soong, ve Yue Wang. 2015. "Improved Mispronunciation Detection with DNN Trained Acoustic Models and Transfer Learning Based Score Normalization". *Speech Communication* 67: 154-66.

<https://doi.org/10.1016/j.specom.2014.11.003>.

Institute of Smart Systems and Artificial Intelligence (ISSAI), Nazarbayev University. 2022. *ISSAI Turkish Speech Corpus (TSC)*. <https://issai.nu.edu.kz/>.

Jadoul, Yannick, Bill Thompson, ve Bart de Boer. 2018. "Introducing Parselmouth: A Python Interface to Praat". *Journal of Phonetics* 71: 1-15.

<https://doi.org/10.1016/j.wocn.2018.07.001>.

Jiang, Lihui. 2024. "Phonetic Feature and Pronunciation Improvement for English Learners". *2024 International Conference on Machine Intelligence and Digital Applications (MIDA)* (Ningbo, China), 557-61.

Kabak, Barış, ve Irene Vogel. 2001. "The Phonological Word and Stress Assignment in Turkish". *Phonology* 18 (3): 315-60. <https://doi.org/10.1017/S0952675701004201>.

Kornfilt, Jaklin. 1997. *Turkish*. Routledge.

Ladefoged, Peter, ve Keith Johnson. 2005. *A Course in Phonetics*. 5. bs. Thomson Wadsworth.

Leung, Wai-Kim, Xunying Liu, ve Helen M. Meng. 2019. "CNN-RNN-CTC Based End-to-End Mispronunciation Detection and Diagnosis". *ICASSP 2019 – 2019 IEEE International Conference on Acoustics, Speech and Signal Processing*, 8132-36.

<https://doi.org/10.1109/ICASSP.2019.8682654>.

Lewis, Geoffrey L. 2000. *Turkish Grammar*. 2. bs. Oxford University Press.

Li, Kun, Xiaojun Qian, ve Helen M. Meng. 2017. "Mispronunciation Detection and Diagnosis in L2 English Speech Using Multidistribution Deep Neural Networks". *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 25 (1): 193-207.

<https://doi.org/10.1109/TASLP.2016.2621675>.

Lin, Binghuai, ve Liyuan Wang. 2021. "Attention-Based Multi-Encoder Automatic Pronunciation Assessment". *ICASSP 2021-2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 7745-49.

<https://doi.org/10.1109/ICASSP39728.2021.9414451>.

Lipton, Zachary C. 2018. "The Mythos of Model Interpretability". *Queue* 16 (3): 31-57.

<https://doi.org/10.1145/3236386.3241340>.

McAuliffe, Michael, Michaela Socolof, Sarah Mihuc, Michael Wagner, ve Morgan Sonderegger. 2017. "Montreal Forced Aligner: Trainable Text-Speech Alignment Using Kaldi". *Interspeech*, 498-502.

Needleman, Saul B., ve Christian D. Wunsch. 1970. "A General Method Applicable to the Search for Similarities in the Amino Acid Sequence of Two Proteins". *Journal of Molecular Biology* 48 (3): 443-53. [https://doi.org/10.1016/0022-2836\(70\)90057-4](https://doi.org/10.1016/0022-2836(70)90057-4).

Neumeyer, Leonardo, Horacio Franco, Vassilis Digalakis, ve Mitchel Weintraub. 2000. "Automatic Scoring of Pronunciation Quality". *Speech Communication* 30 (2-3): 83-93. [https://doi.org/10.1016/S0167-6393\(99\)00046-1](https://doi.org/10.1016/S0167-6393(99)00046-1).

Oflazer, Kemal, ve Murat Saraçlar, ed. 2018. *Turkish Natural Language Processing*. Springer International Publishing. <https://doi.org/10.1007/978-3-319-90165-7>.

Pratap, Vineel, Andros Tjandra, Bowen Shi, vd. 2024. "Scaling Speech Technology to 1,000+ Languages". *Journal of Machine Learning Research* 25 (97): 1-52. <https://jmlr.org/papers/v25/23-1318.html>.

Radford, Alec, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, ve Ilya Sutskever. 2023. "Robust Speech Recognition via Large-Scale Weak Supervision". *Proceedings of the 40th International Conference on Machine Learning*, 28492-518.

Rao, Kanishka, Fuchun Peng, Haşim Sak, ve Françoise Beaufays. 2015. "Grapheme-to-Phoneme Conversion Using Long Short-Term Memory Recurrent Neural Networks". *2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 4225-29. <https://doi.org/10.1109/ICASSP.2015.7178767>.

Rogerson-Revell, Pamela M. 2021. "Computer-Assisted Pronunciation Training (CAPT): Current Issues and Future Directions". *RELC Journal* 52 (1): 189-205. <https://doi.org/10.1177/0033688220977406>.

Sak, Haşim, Murat Saraçlar, ve Tunga Güngör. 2012. "Morpholexical and Discriminative Language Models for Turkish Automatic Speech Recognition". *IEEE Transactions on Audio, Speech, and Language Processing* 20 (8): 2341-51. <https://doi.org/10.1109/TASL.2012.2201477>.

Salor, Özgül, Bryan Pellom, Tolga Çiloğlu, Kadri Hacıoğlu, ve Mübeccel Demirekler. 2002. "On Developing New Text and Audio Corpora and Speech Recognition Tools for the Turkish Language". *7th International Conference on Spoken Language Processing (ICSLP 2002)*, 349-52.

Selen, Nevin. 1979. *Söyleyiş Sesbilimi, Akustik Sesbilim ve Türkiye Türkçesi*. Türk Dil Kurumu.

Sezer, Engin. 1981. "On Non-Final Stress in Turkish". *Journal of Turkish Studies* 5: 61-69.

Shahin, Mostafa, Julien Epps, ve Beena Ahmed. 2025. "Phonological Level wav2vec2-Based Mispronunciation Detection and Diagnosis Method". *Speech Communication* 173: 103249. <https://doi.org/10.1016/j.specom.2025.103249>.

Tombaloğlu, Burak, ve Hamit Erdem. 2016. "Development of a MFCC-SVM Based Turkish Speech Recognition System". *2016 24th Signal Processing and Communication Application Conference (SIU)* (Zonguldak, Turkey), 929-32. <https://doi.org/10.1109/SIU.2016.7495893>.

Underhill, Robert. 1976. *Turkish Grammar*. MIT Press.

Wilson, Edwin B. 1927. "Probable Inference, the Law of Succession, and Statistical Inference". *Journal of the American Statistical Association* 22 (158): 209-12. <https://doi.org/10.1080/01621459.1927.10502953>.

Witt, Silke M., ve Steve J. Young. 2000. "Phone-Level Pronunciation Scoring and Assessment for Interactive Language Learning". *Speech Communication* 30 (2-3): 95-108. [https://doi.org/10.1016/S0167-6393\(99\)00073-5](https://doi.org/10.1016/S0167-6393(99)00073-5).

Wu, Minglin, Kun Li, Wai-Kim Leung, ve Helen Meng. 2021. "Transformer Based End-to-End Mispronunciation Detection and Diagnosis". *Interspeech 2021*, 3954-58. <https://doi.org/10.21437/Interspeech.2021-1467>.

Ye, Wenxuan, Shaoguang Mao, Frank Soong, vd. 2022. "An Approach to Mispronunciation Detection and Diagnosis with Acoustic, Phonetic and Linguistic (APL) Embeddings". *ICASSP 2022 – 2022 IEEE International Conference on Acoustics, Speech and Signal Processing* (Singapore), 6827-31. <https://doi.org/10.1109/ICASSP43922.2022.9746604>.

Yolchuyeva, Sevinj, Géza Németh, ve Bálint Gyires-Tóth. 2019. "Transformer Based Grapheme-to-Phoneme Conversion". *Interspeech 2019*, 2095-99. <https://doi.org/10.21437/Interspeech.2019-1954>.

Zhang, Junbo, Yongqing Zou, Kun Zhou, Chu Yuan Huang, Michael X. Q. Zhao, ve Duc T. Li. 2021. "speechocean762: An Open-Source Non-Native English Speech Corpus for Pronunciation Assessment". *Interspeech 2021*, 3048-52. <https://doi.org/10.21437/Interspeech.2021-1905>.

Zhao, Guanlong, Sinem Sönsaat, Alif Silpachai, vd. 2018. "L2-ARCTIC: A Non-native English Speech Corpus". *Interspeech 2018*, 2783-87. <https://doi.org/10.21437/Interspeech.2018-1110>.

Ziafat, Nishmia, Hafiz Farooq Ahmad, Iram Fatima, Muhammad Zia, Abdulaziz Alhumam, ve Kashif Rajpoot. 2021. "Correct Pronunciation Detection of the Arabic Alphabet Using Deep Learning". *Applied Sciences* 11 (6): 2508. <https://doi.org/10.3390/app11062508>.

Zimmer, Karl, ve Orhan Orgun. 1999. "Turkish". İçinde *Handbook of the International Phonetic Association: A Guide to the Use of the International Phonetic Alphabet*. Cambridge University Press.